

分 类 号: R318
研究生学号: 2018552003

单位代码: 10183
密 级: 公开



吉 林 大 学

硕士学位论文

(学术学位)

sEMG 的特征分析与肌肉疲劳分类研究

Feature Analysis of sEMG and Research on Muscle Fatigue
Classification

作 者 姓 名: 董梦坤

专 业: 精密仪器及机械

领域(方向): 生物医学信号检测技术及仪器

指 导 教 师: 刘光达 教授

培 养 单 位: 仪器科学与电气工程学院

2021 年 6 月

sEMG 的特征分析与肌肉疲劳分类研究

Feature Analysis of sEMG and Research on Muscle
Fatigue Classification

作 者 姓 名：董梦坤

领域（方向）：生物医学信号处理

指 导 教 师：刘光达 教授

类 别：工学硕士

答 辩 日 期：2021 年 5 月 29 日

吉林大学硕士学位论文原创性声明

本人郑重声明：所呈交学位论文，是本人在指导教师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本研究不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：董梦坤

日期：2021年6月1日

关于学位论文使用授权的声明

本人完全了解吉林大学有关保留、使用学位论文的规定，同意吉林大学保留或向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅；本人授权吉林大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或其他复制手段保存论文和汇编本学位论文。

论文级别： ☒ 硕士 ☐ 博士

学科专业： 精密仪器及机械

论文题目： sEMG 的特征分析与肌肉疲劳分类研究

作者签名： 董步坤

指导教师签名： 刘忠达

2021年6月1日

摘要

sEMG 的特征分析与肌肉疲劳分类研究

肌肉疲劳是一种常见的生活现象,通常是经过剧烈运动或者持续性运动后产生,表现为肌肉酸痛、乏力等。当肌肉疲劳到达一定程度会造成人体损伤,为了避免这种情况,可以选择比较合理的生理信号,对人体的疲劳程度进行判断。而肌电信号因便于观察且具有较高的实时性,在评价肌肉疲劳方面备受关注。

肌电信号是由肌肉运动单元产生的电位在时间和空间上叠加,并从肌肉神经元传输到皮肤表面的一种生物电信号。肌电信号可以无损、长期、实时地采集且信号的变化与肌肉的活动水平和功能状态有关。肌电信号采集方式有针式肌电采集和表面肌电采集,表面肌电信号因其无创、便捷的检测优点被广泛应用。

本文为了建立肌肉疲劳分类模型,提高模型的正确识别率,首先,分析了肌电信号的产生机制、特点和去噪方法,在常用时域、频域特征分析方法的基础上,引入了时频域、非线性和参数模型特征分析方法;其次设计了 3 通道表面肌电信号采集系统,每个通道可以提取 16 维特征参数,共提取了 48 维特征参数;然后设计了疲劳诱发实验,提取时域、频域、时频域、非线性和参数模型特征分析其变化规律,采用互信息度量、主成分分析和核主成分分析三种特征降维方法,对特征集进行降维处理,降低特征之间的冗余性;最后将降维后新的特征集与 Fisher 线性判别分析、K 近邻和支持向量机三种分类器相互组合,建立九种疲劳分类模型,对肌肉进行轻松态、疲劳过渡态和疲劳态三种状态的分类,结果表明,核主成分分析与支持向量机组合的模型对于疲劳分类的平均识别率最高,达到 91.5%,高于其他疲劳分类模型。

综上,本文提出的表面肌电信号特征分析与肌肉疲劳分类方法,能够取得较好的疲劳分类结果,对于肌肉疲劳程度的判断具有重要研究意义。

关键字:

表面肌电信号, 肌肉疲劳, 特征降维, 疲劳分类模型

Abstract

Feature Analysis of sEMG and Research on Muscle

Fatigue Classification

Muscle fatigue is a common life phenomenon, which usually occurs after strenuous exercise or continuous exercise, and manifests as muscle aches and fatigue. When muscle fatigue reaches a certain level, it will cause human body damage. In order to avoid this situation, you can choose a more reasonable physiological signal to judge the degree of human body fatigue. The EMG signal has attracted much attention in evaluating muscle fatigue because it is easy to observe and has high real-time performance.

The electromyography signal is a kind of bioelectric signal that is superimposed on time and space by the potential generated by the muscle motor unit and transmitted from the muscle neuron to the surface of the skin. The EMG signal can be collected non-destructively, long-term, and real-time, and the change of the signal is related to the activity level and functional state of the muscle. The EMG signal acquisition methods include needle EMG collection and surface EMG collection. Surface EMG signals are widely used because of their non-invasive and convenient detection advantages.

In order to establish a muscle fatigue classification model and improve the correct recognition rate of the model, firstly, based on the commonly used time-domain and frequency-domain feature analysis methods, the time-frequency domain, nonlinearity and parametric model feature analysis methods are introduced; secondly, 3 channels are designed. Surface EMG signal acquisition system, each channel can extract 16-dimensional feature parameters, and a total of 48-dimensional feature parameters are extracted; then a fatigue induction experiment is designed to extract the time domain, frequency domain, time-frequency domain, nonlinearity and parameter model features and Analyze the law of change, adopt three feature dimensionality reduction methods of mutual information measurement, principal component analysis and kernel principal

II

component analysis to reduce the dimensionality of the feature set to reduce the redundancy between features; finally, the new features after dimensionality reduction Set and Fisher linear discriminant analysis, K-nearest neighbor and support vector machine three classifiers are combined with each other to establish nine fatigue classification models to classify muscles into three states: relaxed state, fatigue transition state, and fatigue state. The results show that the core The model combining component analysis and support vector machine has the highest average recognition rate for fatigue classification, reaching 91.5%, which is higher than other fatigue classification models

In summary, the surface EMG signal feature analysis and muscle fatigue classification methods proposed in this thesis can achieve better fatigue classification results, and have important research significance for the judgment of muscle fatigue.

Keywords:

surface electromyography signal, muscle fatigue, feature dimension reduction, fatigue classification model

目 录

摘 要.....	I
Abstract.....	II
第 1 章 绪论.....	1
1.1 研究背景及意义	1
1.2 国内外研究现状	4
1.3 论文的主要研究内容	6
1.4 论文的结构安排	7
第 2 章 表面肌电信号的产生机制及其特征分析方法	8
2.1 表面肌电信号的产生机制	8
2.2 表面肌电信号的特点	10
2.3 表面肌电信号的噪声处理	10
2.3.1 经验模态分解去噪方法	11
2.3.2 小波阈值去噪方法	13
2.4 表面肌电信号的特征分析方法	17
2.4.1 时域特征分析方法	17
2.4.2 频域特征分析方法	19
2.4.3 时频域特征分析方法	20
2.4.4 非线性特征分析方法	23
2.4.5 参数模型特征分析方法	24
2.5 本章小结	25

第3章 表面肌电信号采集系统	26
3.1 总体设计	26
3.2 硬件检测平台设计	27
3.2.1 采集电路	27
3.2.2 主控电路	28
3.2.3 电源管理电路	29
3.3 上位机处理平台设计	32
3.4 本章小结	33
第4章 特征降维与分类模型的分析方法	34
4.1 特征降维	34
4.1.1 特征选择	35
4.1.2 特征提取	35
4.2 肌肉疲劳分类器选择	37
4.2.1 Fisher 线性判别分析	37
4.2.2 K 近邻.....	39
4.2.3 支持向量机	40
4.3 本章小结	41
第5章 疲劳分类实验与结果分析	42
5.1 疲劳实验方案设计	42
5.1.1 实验对象及材料	42
5.1.2 实验过程	43
5.2 实验结果分析	45

5.2.1 特征分析	45
5.2.2 特征降维分析	52
5.2.3 分类结果分析	56
5.3 本章小结	57
第 6 章 总结与展望	59
参考文献.....	61
作者简介及科研成果	66
致谢.....	67

第 1 章 绪论

1.1 研究背景及意义

随着北京成功申办 2022 年冬季奥林匹克运动会（冬奥会），以及全民健身的推行，体育活动已经成为我们生活中的一部分。通过对挪威、德国、芬兰和加拿大等传统冰雪强国运动员技术的研究，我国冬奥会选手的竞技能力正在以一种飞跃式的速度前进。2014 年索契冬奥会，首次参加冬奥会的张虹以 1 分 14 秒的成绩夺得女子速度滑冰 1000 米比赛冠军，为中国拿下冬奥会速度滑冰历史上第一枚金牌。2018 年平昌冬奥会，在男子 500 米短道速滑的决赛中，中国选手武大靖以 39 秒 58 的成绩打破世界纪录，为中国在男子短道速滑赢得首金。然而如今冰雪项目的胜利不仅取决于运动员的个人能力，科技服务也发挥了重要的作用。运动员获得优秀成绩的前提是需要进行大量的训练，而大量的训练会增加运动员的伤病概率，因为随着训练强度和时间的增加会产生肌肉疲劳，严重时会导致肌肉损伤。因此需要科技服务来检测运动员的疲劳程度，避免肌肉损伤的出现。

在日常生活中，肌肉疲劳是一种常见的现象，通常是指肌肉运动系统出现暂时性功能下降。主观感受上表现为肌肉酸痛、乏力，客观上表现为肌肉最大收缩能力的减小。在生理学上，肌肉疲劳又称为运动性疲劳或者生理疲劳，是由于机体进行长时间的负荷运动，导致人体内的乳酸积累，暂时无法产生持续进行所需动作的力^[1]。关于肌肉疲劳的生理机制，主要有中枢和外周两种因素。中枢学说认为，肌肉疲劳是大脑相关区域持续性兴奋导致的运动神经元输入减少，为了避免机体出现伤害，大脑皮层采取的主动性保护，使人体感受到疲劳；外周学说认为，肌肉疲劳与钙离子的运动干扰，磷酸盐的积累和三磷酸腺苷的减少等细胞内化学物质有关，为了补偿由此产生的影响，机体所做出的适应机制反应^[2]。当肌肉疲劳达到一定程度会造成人体损伤，所以为了避免这种情况，可以选择比较合理的方法，对人体的疲劳程度进行判断。目前衡量疲劳的方法主要有两种：主观评价法和客观评价法。

（1）主观评价法

主观评价法是指人体进行运动时，人主观上对疲劳程度的判断。因为人体主

观感受与心肺功能,运动强度和呼吸系统等因素存在一定联系,会从主观上产生最直接的疲劳感受,如肌力下降、肌肉酸痛等。在机体做功对抗的过程中,大脑皮质接收来自肌肉神经元的疲劳信息,通过对传入疲劳信息的辨别,大脑会产生相应调整的冲动。主观评价法主要以问卷的形式,通过主观疲劳等级量表,让受试人员自我评价主观感受。二十世纪七十年代,瑞典心理学家 Borg 提出了 Borg 主观疲劳等级量表(Rating of Perceived Exertion Scale, RPE)。Borg 主观疲劳等级量表让受试人员凭借运动时的自我感受,来评估此时的疲劳强度。Borg 主观疲劳等级量表应用在各个领域,扮演者重要的角色,如体育运动学、生物医学和生理学等。

(2) 客观评价法

客观评价法可以分为生化测量法和生理测量法。生化测量法一般是通过测量血尿素(Blood Urea Nitrogen, BUN)、尿蛋白(Proteinuria, P)、血清睾酮/皮质醇比值(T/C)、血清肌酸激酶(Serum Creatine Kinase, SCK)等体内化学物质浓度,对人体疲劳程度进行判断^[3],如表 1.1 所示。生化测量法对于疲劳的检测较为准确,但是此方法需要专业人员采集人体的体液,部分体液为有创采集,如图 1.1 所示。而且生化测量法操作复杂,检测分析时间较长,会使人主观上产生一定的抗拒性。

表 1.1 生化指标判断

生化指标	生化指标的疲劳判断
血尿素	可根据训练后第二天血尿素浓度,判断肌肉疲劳,一般分界线为 8.mmol/L
尿蛋白	运动后的第二天如超过正常值,则可以判断为肌肉疲劳
血清睾酮/皮质醇比值	大于个体标准值的 30%,则可以判断为肌肉疲劳
血清肌酸激酶	运动后二十四小时达到顶峰,如未在四十八小时内回落到正常值,则可判断为肌肉疲劳




图 1.1 生化测量

随着计算机和传感器技术的发展，人体生理信号的检测更加准确，逐渐成为国内外关注的热点。生理测量法是检测人体的生理信号，包括脑电、心电和肌电等，通过分析生理信号参数与疲劳之间的关系，对人体疲劳进行判断。如图 1.2 为应用生理测量法检测疲劳。相比于主观评价法和生化测量法，生理测量法能够直接、迅速的反映机体疲劳信息。



图 1.2 生理测量

而近几年，表面肌电信号（Surface Electromyography, sEMG）因其无创、便捷的检测优点在评价肌肉疲劳方面备受关注。表面肌电信号是肌肉收缩时产生的微弱的生物电信号，包含了许多有用的生理信息，在生物医学、运动医学和康复

学等领域扮演着极其重要的角色。

1.2 国内外研究现状

表面肌电的起源可以追溯到十七世纪中叶，意大利科学家 Francesco 在对电鱼的一次实验中发现，电鱼发电的电来自一块特殊的肌肉。18 世纪 80 年代，英国皇家学会 John Walsh 在对电鳗鱼的实验中发现了可视的电火花，经过深入的研究发现，电火花是由电鳗鱼的肌肉收缩产生。但一直到十八世纪末期，才由 Galvani 证实了电位变化与肌肉收缩的直接关系，为后续肌电信号的研究打开了大门。1849 年，Bosi-Reymond 初次证明了人体在肌肉收缩时会产生微弱的电活动。

美国神经科学家 Gasser 和 Erlanger 研制出了阴极射线示波器，可以显示神经纤维上微弱的电活动，而且发现了神经纤维上的电活动以不同速度传播，并获得了 1944 年的诺贝尔医学奖。从此 sEMG 设备不断的发展更新，促进了对 sEMG 信号的研究。国内外已经研制出各种高性能的 sEMG 采集装置，如西安纪变智能科技有限公司研制出了一种手持式表面肌电监测仪，通过无线传输装置，可以将采集处理过的 sEMG 数据传输到上位机进行分析，设备体积小、方便携带^[4]。广州雪利昂生物科技有限公司研制出一种新型表面肌电采集仪，采用了屏蔽导线、信号放大器等处理元件，能够将信号稳定输出，便于分析处理^[5]。计量质量检测研究院的王耀弘研制出了一种适用于表面肌电计量校准的采集仪，利用数字频率以及嵌入操作系统实现输出不同的 sEMG 波形，频率误差率小于 1%^[6]。

国外对于 sEMG 的设备装置的研究更加成熟，其中美国 Delsys 公司研制的无线 sEMG 采集仪应用最为广泛。它包括 16 通道的无线传感器和 3 个自由度的加速度传感器，而且体积小便于携带，续航能力可达 5 小时，如图 1.3 所示。



图 1.3 美国 Delsys 公司的 16 通道无线 sEMG 采集仪^[7]

意大利 Cometa 公司研发的 Wave 系列无线 sEMG 采集仪，可采集肌肉收缩时产生的肌电信号，通过无线传输到配套软件，应用于体育科学研究和康复医学等方面。如图 1.4 所示。



图 1.4 意大利 Cometa 公司的 Wave 无线 sEMG 采集仪^[8]

在 sEMG 分析领域，各种算法和机器学习被广泛应用，很多学者基于 sEMG 对肌肉疲劳展开了深入的研究。李青青等通过分析双侧股内侧肌 sEMG 特征，对其进行回归分析，发现疲劳状态下过零率、平均功率频率和中位频率为三次曲线^[9]。王笃明等通过分析持续负重时主观疲劳等级量表得分与肱二头肌 sEMG 信号，发现特征参数平均功率频率、中值频率和复杂度与主观疲劳等级量表得分成负相关，符合心理物理学中的 Stevens 幂定律^[10]。徐明伟等针对颈部前屈，提取颈部肌肉特征参数平均功率频率，通过计算平均功率频率的导数，结果发现可用导数值的负数积聚来判定肌肉疲劳^[11]。王琳等结合生物力学理论分析颈部肌肉发现，随着疲劳程度的加深，近似熵和疲劳指标 Q 下降，经 t 检验和变异系数分析可知， Q 值对颈肌疲劳的反映最佳^[12]。曹昂等在常用特征积分肌电值、均方根值、中值频率以及平均功率频率的基础上，引入了带谱熵和瞬时平均频率，使用粒子群突变算法优化支持向量机对肌肉疲劳进行分类，准确率大于 90%^[13]。糜超等提取表面肌电的 4 个时域特征积分肌电值、过零率、符号改变率以及波长，采用支持向量机作为分类器，设计一套 8 导联表面肌电采集系统，能够有效的区分肌肉的疲劳与正常两种状态^[14]。张毅等针对在表面肌电信号的人机交互系统的问题，选择瞬时平均频率训练支持向量机模型，可以有效的保持疲劳检测系统的稳定^[15]。付梦龙通过分析疲劳进程中的表面肌电信号特征指标均方根值、自回归参数，并结合线性判别分析分类器，对肌肉疲劳程度实时检测^[16]。Edward 等记录了 50 名健康志愿者的 sEMG 信号，基于阶频谱相关的肱二头肌表面肌电信号的分析，发现随着疲劳加深近似熵和样本熵显著降低，表明使用阶频谱相关方法能够区分

疲劳状态^[17]。Moniri 等采用浅层模型和深度卷积神经网络实时学习预测 5 种常见的表面肌电特征，提供了一个通用的模型，为的体育活动提供准确预测^[18]。Bueno 等从肌肉收缩时产生的肌电信号的不同指标出发，采用概率学方法，基于高斯混合模型分析肌肉疲劳^[19]。Xu 等基于混合的多类高斯过程模型提出了一种混合细菌觅食和粒子群算法来优化未知参数，通过在飞行模拟器中进行飞行模拟来进行实验，此方法对于飞行员的颈部疲劳的识别精度达到 91.25%^[20]。

直接利用表面肌电信号的特征参数，虽然也有较好的识别效果，但是特征参数之间具有很大的相关性和冗余性，没有考虑算法的复杂度，往往影响疲劳模型的分类识别率。因此本文为了解决此问题，在原始特征参数不损失原有信息的前提下，采用不同的特征降维方法，去除冗余信息，得到新的特征集，最后利用多种分类器检验分类效果，从中找出最有效的一种疲劳分类模型。

1.3 论文的主要研究内容

论文的研究基于国家重点研发计划项目“科技冬奥专项”。通过分析肌肉疲劳与表面肌电信号之间联系，提出了一种基于 sEMG 的特征分析与肌肉疲劳分类方法，主要研究内容包括：

（1）根据当前对表面肌电信号的研究与分析，在常用时域、频域特征分析方法的基础上，引入了时频域、非线性和参数模型特征分析方法。为了防止皮脂、其他生理信号和器件固有噪声等对疲劳检测的影响，在数据预处理时，分别采用经验模态分解和小波阈值去噪对表面肌电信号进行降噪处理，比较两种方法的降噪指标，找出降噪效果较好的方法。

（2）在表面肌电信号特点和测量原理的基础上，设计了 3 通道表面肌电信号采集系统，包括硬件检测平台和上位机处理平台，其中硬件检测平台完成对表面肌电信号的采集、放大和滤波，上位机处理平台完成表面肌电信号的数据处理和分析。

（3）设计疲劳诱发实验，通过自主开发的 sEMG 采集系统采集静态负荷下手臂 3 块肌肉的表面肌电信号，提取表面肌电信号的时域、频域、时频域、非线性和参数模型特征参数，分析疲劳过程中，表面肌电信号的特征变化规律，并对各特征之间进行相关性分析。

(4) 根据 Borg 主观疲劳等级量表并结合表面肌电信号的变化规律, 为数据标注标签, 分为轻松态、疲劳过渡态和疲劳态。使用互信息度量、主成分分析和核主成分分析三种降维算法, 对提取的 48 维特征进行降维处理, 降低特征之间的冗余性。然后选择 Fisher 线性判别分析、K 近邻和支持向量机作为分类器, 将降维后的新的特征子集带入分类器中进行训练, 建立九种疲劳分类模型。最后, 通过实验结果对九种疲劳分类模型进行比较, 选择最优疲劳分类模型。结果表明, 核主成分分析与支持向量机组合的分类模型对于疲劳判断平均识别率最高。

1.4 论文的结构安排

论文共分为 6 章, 具体的结构安排如下:

第 1 章, 绪论。阐述了肌肉疲劳的研究背景及意义, 分析了国内外学者针对表面肌电的肌肉疲劳研究现状, 最后概括的介绍了论文的主要研究内容与结构安排。

第 2 章, 表面肌电信号的产生机制与特征分析方法。首先介绍了表面肌电信号的产生机制与特点, 然后分析了经验模态分解和小波阈值去噪方法特点, 最后介绍了表面肌电信号的特征分析方法, 包括时域特征分析方法、频域特征分析方法、时频域特征分析方法、非线性特征分析方法和参数模型特征分析方法。

第 3 章, 表面肌电信号采集系统。本章节首先介绍了硬件检测平台设计, 根据 sEMG 的特点, 研发出可以稳定采集并输出的表面肌电信号采集器。然后介绍了上位机处理平台设计, 设计了可视友好化的显示界面。

第 4 章, 特征降维与分类模型的分析方法。首先介绍了特征降维技术, 包括特征提取与特征选择, 接着介绍了 Fisher 线性判别分析、K 近邻和支持向量机三种分类器以及各自的特点。

第 5 章, 疲劳分类实验与结果分析。包括疲劳诱发实验的设计, 分析受试者在疲劳过程中各特征参数的变化规律。将肌肉状态分为轻松态、疲劳过渡态和疲劳态, 通过实验结果, 对三种降维方法与三种分类器组合的肌肉疲劳模型做出分析总结。

第 6 章, 总结与展望。对论文做出总结, 对研究成果的创新点进行评价, 并对未来的研究方向进行了展望。

第2章 表面肌电信号的产生机制及其特征分析方法

肌肉疲劳在生活中很常见，也是许多肌肉疾病的重要指标，如肌营养不良和疾病。因此，及时的评估肌肉疲劳对于避免疾病恶化和追踪疾病进展十分重要，经研究统计，每 3500 名男性中就有一人受到影响，迄今为止尚未治愈。表面肌电信号是记录肌肉收缩过程中肌纤维的电活动，其用途之一就是评估肌肉在疲劳收缩过程中的变化，为运动员制定合适的训练方案和康复训练。然而表面肌电信号受多种因素的影响，表现出一定的复杂性。一些研究表面肌电信号复杂性行为的研究表明，肌电信号的本质上是非线性的，具有低维混沌性质的特征，许多复杂度指标被用来表现 sEMG 在肌肉激活和疲劳时的变化^[21]。

2.1 表面肌电信号的产生机制

肌电信号是肌肉收缩产生并从肌肉神经元传输到皮肤表面的一种生物电信号，肌电信号采集的方式有两种，一种是将同芯针电极插入肌肉内，通过记录肌肉的运动神经单元的电位变化，即针式肌电；一种是通过表面肌电传感器的电极贴于皮肤表面，通过电极差来采集肌肉的肌电信号，即表面肌电^[22]。表面肌电是一种无创的采集方式，应用比较广泛。

根据肌肉收缩过程中神经纤维传导的过程，神经系统对肌肉收缩的调控一般可以分成三部分，包括大脑皮层、脊髓、肌肉^[23]。大脑皮层是控制人体运动的最高级中枢，在人体即将运动时，大脑皮层向中枢神经元传递命令，将其以神经冲动的形式传递至脊髓。如图 2.1 所示。




图 2.1 神经系统对肌肉的调控^[24]

脊髓是神经系统的组成部分，其中存在着大量的运动神经单元，它是肌肉收

缩的最小功能单位，一个运动神经单元和被其控制的肌纤维构成一个运动单位（MU），如图 2.2 所示。其中 α -运动神经单元又与皮质脊髓相联系，为肌肉提供最直接的控制^[25]。而表面肌电信号是由多个肌纤维运动单元的叠加形成，产生的信号称成为肌纤维运动单元的动作电位（MUAP）^[26]。




图 2.2 运动单元示意图^[27]

肌肉收缩前之前会有一系列的电生理事件，从脊髓中运动神经单元的激发到动作电位在肌肉管的传播，如图 2.3 所示。运动神经元将刺激冲动时产生的 MUAP 通过激活的神经元传递至神经轴的末梢，轴突膜电压门控 Ca^{2+} 通道打开， Ca^{2+} 内流产生浓度差，使囊泡释放能够诱导肌纤维产生动作电位的一种化学物质—乙酰胆碱（ACh）^[28]。乙酰胆碱与终板膜上化学门控通道的两个 α -亚单位结合，形成终板电位， Na^+ 内流， K^+ 外流，最终肌细胞去极化达到阈值电位，肌纤维兴奋收缩，完成相应的动作。




图 2.3 脊髓中运动神经单元^[29]

2.2 表面肌电信号的特点

表面肌电信号是神经肌肉系统产生的微弱的生物电信号，其幅度范围在 0~5mV，频率在 20Hz~1000Hz 之间，其功率谱随着肌肉运动纤维的抵抗力变化而变化，主要能量集中在 50Hz~150Hz 范围内^[30]。在时域特性上，不同肌肉群上表面肌电信号，它们的幅值大小存在一定的范围差距；频率特性上，不同肌群的表面肌电信号，它们的功率谱上的分布也存在一定的范围差距^[31]。图 2.4 为典型的表面肌电信号波形图。




图 2.4 表面肌电信号波形图^[32]

表面肌电信号是肌肉运动单元产生的电位在人体皮肤表面叠加形成，是一种易受干扰的生理信号，其中以工频干扰和基线漂移最为严重^[33]。我国的工频干扰主要来自于设备接入供电，为 50Hz 左右，因此需要对采集到的原始表面肌电信号进行 50Hz 的陷波滤除工频干扰。而对于非线性、非平稳、易受基线漂移噪声干扰的表面肌电信号，经研究表明小波阈值去噪方法和经验模态分解去噪方法，能够既保留 sEMG 信号的有效信息，得到高质量的表面肌电信号，也能够滤除噪声干扰^[34]。

2.3 表面肌电信号的噪声处理

在采集表面肌电信号的过程中，各种噪声的干扰无法避免，主要包括其他生物电信号，如心电信号；工频干扰，指 50Hz 频率、220V 以电磁波形式辐射的电压；硬件设备的固有噪声，主要来自硬件中的电子器件。为了采集更加有效的 sEMG，提取有效的肌肉信息，需要对 sEMG 进行噪声处理。在本文中，对表面

肌电信号分别进行经验模态分解和小波阈值去噪两种降噪方法,通过比较两种方法的降噪指标,选择更优的降噪方法,来完成对表面肌电信号的去噪分析。

2.3.1 经验模态分解去噪方法

经验模态分解 (Empirical Mode decomposition, EMD) 是对一个信号进行平稳化处理,将信号分解成多个不同时间尺度的内蕴模式函数 (Intrinsic Mode Function, IMF) 分量,然后将内蕴模式函数进行希尔伯特变换^[35]。经验模态分解常常应用于分析非平稳和非线性信号,可以反映原本信号的固有性质。使用经验模态分解的信号必须满足以下两个 IMF 条件: 第一在整个数据段中,极点的数目与过零点的数目相同或者最多相差 1 个点;第二由极大点产生的上包极大络线和极小值产生的下包极小络线的均值为 0。

EMD 去噪的具体流程如下:

(1) 给定原始信号 $x(t)$, 选择其所有的极值点

(2) 对极大值进行三次样条曲线拟合,得到上包络线 $\gamma_{\max}(t)$; 对极小值进行三次样条曲线拟合,得到下包络线 $\gamma_{\min}(t)$ 。计算上下包络的平均曲线,公式如下所示:

$$m(t) = \frac{\gamma_{\max}(t) + \gamma_{\min}(t)}{2} \dots\dots\dots (2.1)$$

(3) 用原始信号 $x(t)$ 减去平均包络 $m(t)$

$$g(t) = x(t) - m(t) \dots\dots\dots (2.2)$$

(4) 然后判断式子 (2.2) 得到的 $g(t)$ 是否满足上述两个 IMF 条件, 如果不满足, 则继续将 $g(t)$ 作为 $x(t)$, 重复执行以上 (1) ~ (3) 步骤; 如果满足, 则 $g(t)$ 是一个 IMF, 记 $c_1(t) = g_1(t)$, 剩余部分信号为:

$$r_1(t) = x(t) - c_1(t) \dots\dots\dots (2.3)$$

(5) 将 $r_1(t)$ 作为 $x(t)$, 再次执行以上步骤 (1) ~ (4), 得到满足 IMF 条件的第二个分量 $c_2(t)$, 重复 n 次, 直至得到所有满足 IMF 条件的分量。则可以得

到

$$x(t) = \sum_{i=1}^n c_i(t) + r_n(t) \cdots \cdots \cdots (2.4)$$

其中 $c_i(t)$ 为第 i 次得到的 IMF 信号, $r_n(t)$ 为最后的剩余信号, 即残余函数。

从经验模态分解的具体流程可以看出, 它实际上就是一个“筛选”的过程, 随着分离次数的增加, 得到的频率分量越来越小, 从而使波形的形状更加对称。

EMD 分解的流程框图如图 2.5 所示。




图 2.5 EMD 分解的流程框图

经验模态分解优点有具有自适应性, 正交性, 滤波后的信号能够最大程度保留完备性。本文为了验证经验模态分解对于表面肌电去噪的有效性, 对提取 1000

个采样点的表面肌电信号进行 6 层 EMD 分解，各层 IMF 分量如图 2.6 所示。




图 2.6 表面肌电信号各层 IMF 分量

如图 2.6 可以看出各层的 IMF 分量的频率不同，其中 IMF1~IMF3 频率较高，为表面肌电信号的高频部分。

2.3.2 小波阈值去噪方法

十九世纪九十年代，斯坦福大学的教授 Donoho 和 Johnstone 提出了小波变换阈值去噪的方法，使用最小均方误差，使最终的结果接近最优解。小波阈值去噪的基本原理是：将含有噪声的信号使用小波分解，有效信号的能量在幅度较大的小波系数上，而噪声信号则在幅度较小的小波系数上。然后设定恰当的阈值，保留有效信息，滤除干扰噪声。最后利用保留的小波系数进行小波重构，得到滤波后的有效信号。

小波阈值去噪可以将表面肌电信号视为一维信号模型，其公式如下所示：

$$x(k) = f(k) + \sigma * e(k), k = 1, 2, \dots, n-1 \dots\dots\dots (2.5)$$

其中 $s(k)$ 为含有噪声信号的表面肌电信号， $f(k)$ 为有效信号， $e(k)$ 为噪声信号。

在实际情况中，有效信号一般为低频信号，而噪声信号则相应为高频信号。去噪过程框图如图 2.7 所示，在小波阈值去噪的过程中 $e(k)$ 逐渐从原始表面肌电信号

$s(k)$ 被滤除，得到真实信号 $f(k)$ 。




图 2.7 小波阈值去噪过程框图

小波阈值去噪的过程如下：

(1) 选择与噪声相似的小波基函数和分解的层数，然后对信号进行小波分解，提取分解后的小波系数，如图 2.8 所示。其中， $a_1 \sim a_3$ 为高频信号， $d_1 \sim d_3$ 为低频信号，而最后的有效信息包含在 a_3 中。




图 2.8 小波分解

(2) 采用合适方法确定高频段系数，为小波选定阈值，对高频段部分中的不在阈值范围内的小波系数进行阈值处理，产生新的高频段部分。

(3) 将得到的新的小波系数进行小波逆变换，重构出去噪后的表面肌电信号。

本文选择 Daubechies (dbN) 小波基函数进行小波阈值去噪。Daubechies 小波基函数是一种具有阶层性质的、正交的、符合离散小波分析方式、尺度为 2 的整数幂次方构造出的小波，可以记为 dbN, $N=1,2,\dots,10$ 。如图 2.9 为使用 db4 小波函数去噪。




图 2.9 db4 小波函数去噪

选择不同阈值准则会得到不同降噪效果，常用的阈值化操作有固定阈值和自适应阈值化等。本文选择固定阈值 (sqtwolog) 作为阈值准则，滤除高频小波系数。固定阈值是在噪声具有独立分布的前提下，通过设置阈值来去除信号中噪声。在 N 个具有独立同分布的高斯变量中，最大值小于阈值的概率随着 N 的增加趋近于 1，因此，设未去噪的原始信号 $s(k)$ 在尺度 $1\sim m$ 上通过小波分析，可以得到小波系数 n 以及标准差 σ ，则固定阈值可以表示为

$$T = \sigma \sqrt{2 \ln(n)} \dots\dots\dots (2.6)$$

对提取的 1000 个采样点的表面肌电信号进行小波阈值去噪处理，去噪前后对比图如图 2.10 所示。




图 2.10 去噪前后对比

由图 2.10 可以看出，原始表面肌电信号存在一定的高频噪声干扰，经去噪后，保留下了 sEMG 中的低频有效部分。表明了小波阈值去噪能够有效的去除高频干扰噪声，保留信号中的有用信息。为接下来的表面肌电信号的特征提取做准备。

本文从信噪比（SNR）和均方根误差（RMSE）两个降噪效果指标进行定量评价，表 2.1 为两种降噪效果指标比较。

信噪比是指信号与噪声的比例，单位为分贝（db），计算公式如下所示：

$$SNR = 10 \lg \frac{P_s}{P_n} \dots\dots\dots (2.7)$$

式中 P_s 为信号的有效功率， P_n 为噪声的有效功率，信噪比 SNR 越大，表明信号的噪声越小。

均方根误差的计算公式如下所示：

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=0}^{N-1} (x_{obs,i} - x_{model,i})^2} \dots\dots\dots (2.8)$$

式中 $x_{obs,i}$ 为未降噪的原始信号， $x_{model,i}$ 为降噪后的信号。

表 2.1 两种降噪效果指标比较

降噪指标	EMD 降噪	小波阈值降噪
信噪比	12.706	18.465
均方根误差	8.168	3.789

从表 2.1 可以看出，小波阈值降噪的信噪比为 18.465，大于 EMD 降噪的信噪比，表明去噪后的信号有效功率更大。对于 RMSE，表面肌电信号经小波阈值降噪后的数值为 3.789，小于经验模态分解的 8.168。通过对小波阈值降噪和 EMD 降噪后两种指标的比较，可以发现，小波阈值降噪效果更好，因此本文选择小波阈值降噪方法对表面肌电信号进行降噪处理。

2.4 表面肌电信号的特征分析方法

表面肌电信号的特征提取是建立疲劳模型的重要环节，一个好的疲劳分类模型与特征的选择有最为直接的关系。关于 sEMG 的特征研究主要有三方面，包括肌电信号的时域特征参数，如积分肌电值、均方根值等；频域特征参数，如平均功率频率、中位频率等；时频域特征参数，如瞬时平均频率、瞬时中位频率等^{[36]~[38]}。表面肌电信号是十分重要的生理信号，它不仅包含线性成分，而且包含非线性成分^[39]。复杂性特征参数是对表面肌电信号序列复杂程度的一个相关描述，常用的复杂性特征参数有复杂度、近似熵、样本熵等^{[40]~[42]}。其中在探究屈肘肌力与表面肌电的特征之间的关系时，样本熵对于评价神经肌肉系统状态与功能优于其他特征^[43]。

2.4.1 时域特征分析方法

表面肌电信号的时域特征能够反映信号在时间维度的变化，从时间角度出发，将表面肌电信号理解为时变函数，具有计算量简单、快速的优点^[44]。常用特征如均方根值、积分肌电值、平均绝对值、过零率、方差和幅值立方均值。

(1) 均方根值 (Root Mean Square, RMS)

均方根值表示表面肌电信号在单位时间内的变化，可以反应肌肉的活跃程度^[45]。公式如下所示：

$$RMS = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2} \dots\dots\dots (2.9)$$

式中, $x_i (i=1,2,\dots,N)$ 是信号的时间序列, N 为选取的帧数长度。

(2) 积分肌电值 (Integrated EMG, iEMG)

积分肌电值表示肌纤维的电荷的活动程度, 反应表面肌电信号的幅值随着运动变化而变化^[46]。公式如下所示:

$$iEMG = \sum_{i=1}^N |x_i| \dots\dots\dots (2.10)$$

式中, $x_i (i=1,2,\dots,N)$ 是信号的时间序列, N 为选取的帧数长度。

(3) 平均绝对值 (Mean Absolute Value, MAV)

平均绝对值常用于识别肌肉的状态分类。公式如下所示:

$$MAV = \frac{1}{N} \sum_{i=1}^N |x_i| \dots\dots\dots (2.11)$$

式中, $x_i (i=1,2,\dots,N)$ 是信号的时间序列, N 为选取的帧数长度。

(4) 过零率 (Zero Crossing Rate, ZCR)

过零率是指 sEMG 单位时间内符号变化的比率, 是时域分析的一个重要指标。公式如下所示:

$$ZCR = \sum_{i=1}^{N-1} \text{sgn}(-x_i x_{i-1}) \dots\dots\dots (2.12)$$

式中, $x_i (i=1,2,\dots,N)$ 是信号的时间序列, N 为选取的帧数长度。

(5) 方差 (Variance, VAR)

方差是用于衡量随机变量离散程度的参数。公式如下所示:

$$VAR = \frac{\sum_{i=1}^N (x_i - \bar{x_i})^2}{N} \dots\dots\dots (2.13)$$

式中, $x_i (i=1,2,\dots,N)$ 是信号的时间序列, N 为选取的帧数长度。

(6) 幅值立方均值 (Amplitude Cubic Mean, ACM)

幅值立方均值可以在时域上反应表面肌电信号振幅的变化规律。公式如下所

示:

$$ACM = \frac{1}{N} \sum_{i=1}^N x_i^3 \dots\dots\dots (2.14)$$

式中, $x_i (i=1,2,\dots,N)$ 是信号的时间序列, N 为选取的帧数长度。

2.4.2 频域特征分析方法

表面肌电的频域特征是将信号通过快速傅里叶变换 (FFT), 根据信号的功率谱或频谱进行分析^[47]。常用指标有平均功率频率、谱矩和中位频率。

(1) 平均功率频率 (Mean Power Frequency,)

平均功率频率随着肌肉疲劳加深出现下降, 其原因是 pH 值降低, 导致肌肉纤维传导速度降低^[48]。公式如下所示:

$$MPF = \frac{\int_0^{\infty} f \times PSD(f) df}{\int_0^{\infty} PSD(f) df} \dots\dots\dots (2.15)$$

式中 f 为 sEMG 信号的频率, $PSD(f)$ 为 sEMG 信号的功率谱密度函数。

(2) 谱矩 (Spectral Moment, SM)

谱矩是 Dimitrov 等人提出一组肌肉疲劳参数, 其中 2 阶谱矩常用于描述高频率的变化情况^[49]。公式如下所示:

$$SM_2 = \int_0^{\infty} f^2 PSD(f) df \dots\dots\dots (2.16)$$

式中 f 为 sEMG 信号的频率, $PSD(f)$ 为 sEMG 信号的功率谱密度函数。

(3) 中值频率 (Media Frequency, MF)

在对肌肉疲劳估计的研究中发现, 表面肌电信号的低频分量随着肌肉疲劳而增加, 量化低频分量部分的代表性指标是中值频率^[50]。公式如下所示:

$$MF = \frac{1}{2} \int_0^{\infty} PSD(f) df \dots\dots\dots (2.17)$$

式中 f 为 sEMG 信号的频率, $PSD(f)$ 为 sEMG 信号的功率谱密度函数。

2.4.3 时频域特征分析方法

时域分析是在时间域上对信号进行分析,研究时间与信号幅度的变化关系;频域分析则是在频率域上对信号进行分析,研究频率变化。时域分析或频域分析都是将表面肌电信号看成是一种连续的平稳信号,但是表面肌电信号是一种非平稳的时变信号,而时频分析法可以同时获得信号在时域和频域的能量信息图,用于分析非平稳信号。

1946年 Gabor 提出了 Gabor 变换,这种变换方法可以同时提取信号的时域特征和频域特征,提供了时间域和频率域的联合分布信息,打开了时频分析的大门。经过了众多学者的研究,时频分析法已经应用于各个领域,成为分析非平稳时变信号的一个重要方法。分析时频域的方法主要有短时傅里叶变换(Short-time Fourier Transform, STFT), Choi-Williams 分布, Wigner-Ville 分布和小波变换(Wavelet Transform, WT)等。

(1) 短时傅里叶变换

短时傅里叶变换是和傅里叶变换相关的一种变换,可由傅里叶变换来实现,是目前比较常用的一种时频分析方法。STFT 原理是把一段长的非平稳信号看成无数段短时间平稳信号的叠加。对于信号 $x(t)$,用移动时间窗分解为无数段等时间长度的短时信号,这样在这段时间内可以把它看成平稳信号,然后对它进行傅里叶变换,得到信号的时频域信息。

定义函数 $STFT(w, \tau)$,表示在窗函数中心为 τ 时,对原函数进行变换后的频谱结果,公式如下所示:

$$STFT(w, \tau) = \int_{-\infty}^{+\infty} [x(\tau)w(t-\tau)]e^{-jw\tau} d\tau \dots\dots\dots (2.18)$$

在短时傅里叶变换中,每一个不同的时间,经变换后都可以得到一个不同的频谱,这些频谱合起来就是时频分布^[51]。窗的长度决定频谱图的时间、频率分辨率,窗的长度越长,其傅里叶变换后的频域分辨率越高,但是时间分辨率越低;反之,窗越短,其傅里叶变换后的频域分辨率越低,但是时间分辨率越高。因此,在实际应用中需要根据情况,在时间分辨率和频域分辨率之间进行取舍。虽然短时傅里叶变换的算法十分简单,可以处理非平稳信号,应用于各个领域,但是其自适应能力较差。

(2) Wigner-Ville 分布

1932 年 Winger 提出了一种时频分析法,并应用于量子力学领域,后来 Ville 将此方法引入信号分析领域,形成了 Winger-Ville 分布。

信号的 Winger-Ville 分布可以定义为:

$$W_{x,y}(t, \omega) = \int_{-\infty}^{+\infty} x(t + \frac{\tau}{2}) y^*(t - \frac{\tau}{2}) e^{-j\omega\tau} d\tau \dots\dots\dots (2.19)$$

式 (2.19) 又称双线性时频分析方法,也可以表示为信号 $x(t)$ 的自 Winger-Ville 分布形式,公式如下所示:

$$W_x(t, \omega) = \int_{-\infty}^{+\infty} x(t + \frac{\tau}{2}) x^*(t - \frac{\tau}{2}) e^{-j\omega\tau} d\tau \dots\dots\dots (2.20)$$

根据 Winger-Ville 分布的定义,对信号任意 t 时刻的频谱,以 t 时刻为中心,将 t 时刻左右的信号相乘,全部结果进行叠加后再做傅里叶变换,由于信号不是单一分量,会在计算当中产生相互作用,形成交叉项^[52]。当 Winger-Ville 分布的交叉项分量较大时会出现一定的交叉干扰,经常会掩盖有用的时频信息。为了避免 Winger-Ville 分布在时频平面处产生的交叉干扰,引入窗函数,可以对 $x(t)$ 进行加窗,得到加窗后的 Winger-Ville 分布定义如下所示:

$$W_{xh}(t, \omega) = \int_{-\infty}^{+\infty} x(t + \frac{\tau}{2}) x^*(t - \frac{\tau}{2}) h(\frac{\tau}{2}) h(-\frac{\tau}{2}) e^{-j\omega\tau} d\tau \dots\dots\dots (2.21)$$

式中 $h(\tau)$ 是窗函数,相当于在频域上对 Winger-Ville 分布进行平滑处理。

相比于短时傅里叶变换, Winger-Ville 分布可以准确的识别信号是单分量还是多分量,得到较好的时频信息。但是 Winger-Ville 分布不同的频率成分会引起交叉项的干扰,虽然加窗后会对交叉项干扰有一定的抑制,但是无法完全消除其存在。

(3) Choi-Williams 分布

Choi-Williams 分布是针对 Winger-Ville 分布问题不足提出的改进算法。为了完成在相关域内对模糊函数的滤波,消除由互模糊函数形成的交叉项干扰,Choi 和 Williams 提出了用核函数的方法。定义如下所示:

$$C_z = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} z(u + \frac{\tau}{2}) z^*(u - \frac{\tau}{2}) \psi(t - u, \tau) e^{-j\omega\tau} du d\tau \dots\dots\dots (2.22)$$

式中 $\psi(t - u, \tau)$ 为 Cohen 类时频分布核函数。

Choi-Williams 分布的核函数公式如下所示:

$$\psi_n(t, l) = \frac{f_s}{\sqrt{4\pi\alpha\tau^2}} \exp\left(-\frac{t^2}{4\alpha l^2}\right) \dots\dots\dots (2.23)$$

式中, f_s 信号的采样频率。将核函数 $\psi_n(t, l)$ 带入式(2.23), 可以得到 Choi-Williams 分布定义, 公式如下所示:

$$CWD_z(t, f) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \frac{1}{\sqrt{4\pi\alpha\tau^2}} \exp\left(-\frac{(t-u)^2}{4\alpha\tau^2}\right) \dots\dots\dots (2.24)$$

Choi-Williams 分布具有在时频域内调节的平滑窗, 制止了模糊函数引起的交叉项干扰, 可以很好的显示信号的各频率分量, 但是对于多分量信号, 其模糊函数形成的交叉项仍分布在相关域上, 并不能完全的过滤交叉项^[53]。

(4) 小波变换

小波变换是在时间尺度上采用可以平移、伸缩的小波进行变换, 解决了短时傅里叶变化的时间窗的问题。

设函数 $\psi(t) \in L^2(R)$, 其傅里叶变换为 $\varphi(w)$ 。当 $\varphi(w)$ 符合式(2.25)约束条件时, 称 $\psi(t)$ 为母小波。

$$C_\psi = \int_R \frac{|\varphi(w)|^2}{|w|} dw < \infty \dots\dots\dots (2.25)$$

母小波函数 $\psi(t)$ 平移伸缩变换后, 可以得到一个小波序列


$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right), a, b \in R, a \neq 0 \dots\dots\dots (2.26)$$

式中 a 为小波序列的伸缩因子, b 为小波序列的平移因子。对于任意信号 $f(x) \in L^2(R)$, $f(x)$ 的小波变换可以记为:

$$WT_x(a, b) = \frac{1}{\sqrt{|a|}} \int_R f(x) \overline{\psi\left(\frac{t-b}{a}\right)} dt \dots\dots\dots (2.27)$$

式中 $\overline{\psi\left(\frac{t-b}{a}\right)}$ 为函数 $\psi\left(\frac{t-b}{a}\right)$ 的共轭函数。

通过改变伸缩因子 a 和平移因子 b , 从而实现对信号不同分辨率和更加细致的分析, 图 2.11 给出了表面肌电信号的时频图。



2.11 小波变换时频图

Karlesson^[54]等比较了以上几种时频分析法，发现小波变换具有更好的准确性。本文采用小波变换计算 sEMG 的时频域特征瞬时平均频率和瞬时中值频率，公式如下所示：

瞬时平均频率（Instantaneous mean power frequency, IMPF）

$$IMPF = \frac{\int_{f_1}^{f_2} f \times PSD(t, f) df}{\int_{f_1}^{f_2} PSD(t, f) df} \dots\dots\dots (2.28)$$

瞬时中值频率（Instantaneous median frequency, IMF）

$$\int_{f_1}^{IMF} PSD(t, f) df = \int_{IMF}^{f_2} PSD(t, f) df \dots\dots\dots (2.29)$$

式中 f 为 sEMG 信号的频率， $PSD(t, f)$ 为频率和时间的二维函数。

2.4.4 非线性特征分析方法

肌肉处于不同的收缩状态下，运动神经单元在时间、空间以及数量上存在一定的差异，因此 sEMG 具有明显的非线性特点^[55]。因此提出了一种新的分析方法，复杂度和非线性共同分析的时间序列方法—熵，熵值越大，信号所包含的信息就越复杂。本文提取表面肌电信号的近似熵作为研究的非线性特征参数。

近似熵（Approximate Entropy, ApEn），于 1991 年由 Steven M.Princus 提出，是一种不可预测性的用于量化时间序列波动的非线性动力学特征参数，是时间序

列片段从 m 维增加到 $m+1$ 维时的平均相似率，反映了时间序列中新信息发生的可能性。用一个非负的数来表征时间序列的复杂程度， $ApEn$ 越大，说明序列越复杂^[56]。 $ApEn$ 的算法原理如下：

对于 n 点时间序列： $\{X(i), i = 1, 2, \dots, n\}$ ，以 m 为窗，将时间序列分为 $n-m+1$ 个 m 维矢量

$$X(i) = [x(i), x(i+1), \dots, x(i+m-1)], i = 1, 2, \dots, n-m+1 \dots\dots\dots (2.30)$$

计算每个矢量与所有矢量之间的距离，并列表

$$d_{ij} = \max |x(i+k) - x(j+k)|, k = 0, 1, \dots, m-1 \dots\dots\dots (2.31)$$

给定阈值 F ，统计表中每一行大于 F 的个数占总数的 $n-m+1$ 的比值，记为 $C_i^m(t)$ ，然后计算其对数平均值

$$\Phi^m(t) = \frac{\sum_{i=1}^{n-m+1} \ln C_i^m(t)}{n-m+1} \dots\dots\dots (2.32)$$

其中 $F = r \times SD$ ， r ：0.1-0.25 系数， SD 为序列标准差。

将窗 m 增加为 $m+1$ ，重复式 (2.31) 和 (2.32) 步骤，得到 $\Phi^{m+1}(t)$ 。

最后计算此序列的近似熵

$$ApEn = \Phi^m(t) - \Phi^{m+1}(t) \dots\dots\dots (2.34)$$

2.4.5 参数模型特征分析方法

参数模型法是分析肌肉疲劳的一个重要方法，其中自回归 (Autoregressive, AR) 模型法最为典型。AR 模型描述的是一种短时平稳随机过程，该过程在该时刻的值 x_n 与该时刻之前的值 x_{n-1} 存在相关性^[57]。设 p 阶 AR 参数模型的公式为

$$x_n = -\sum_{i=1}^p a_i(n)x_{n-i} + e_n \dots\dots\dots (2.35)$$

式中 x_n 为表面肌电信号的第 n 个采样值， $a_i(n)$ 是 AR 系数， p 是 AR 模型的阶数， e_n 为均值为 0，方差为 σ^2 的白噪声。经研究表明，当 AR 模型的阶数取 4 时，对信号的分析 and 识别性能最好^[58]。因此本研究采用 4 阶 AR 参数模型，公式如下

所示:

$$x_n = -\sum_{i=1}^4 a_i(n)x_{n-i} + e_n \quad (2.36)$$

2.5 本章小结

本章首先介绍了表面肌电的产生机制和特点,针对 sEMG 信号容易受到皮脂、其他生物电信号和元器件固有噪声干扰的问题,选择经验模态分解和小波阈值去噪两种降噪方法分别对原始数据进行降噪处理,比较两种降噪方法的效果指标,最后选择小波阈值去噪作为 sEMG 的降噪方法。根据表面肌电信号的生理特征,介绍了表面肌电信号的时域、频域、时频域、非线性和参数模型特征提取方法中常用的特征以及各类特征的特点。

第3章 表面肌电信号采集系统

表面肌电信号是由肌肉神经元产生并通过肌肉组织和皮下脂肪传达到皮肤表面的信号，幅值范围为 $10\mu\text{V}\sim 5\text{mV}$ 之间。表面肌电信号在采集时，常常会受到皮肤表面的油脂、皮肤活性和心电等因素干扰，影响表面肌电信号的真实性，对分析肌肉的状态产生一定阻力。根据表面肌电信号的信号特点，本文研制出了一种表面肌电信号采集系统，该系统以 STM32 系列的微处理器为主控 CPU，MyoWare 肌电传感器为表面肌电的前端采集传感器。通过该系统，实现对表面肌电信号的采集，然后将信号传递至上位机处理平台进行后续的数据分析处理。

3.1 总体设计

为了能够获得可供分析的表面肌电信号，本文设计了三通道表面肌电信号采集系统，系统的总体框架如图 3.1 所示。整个表面肌电信号采集系统包括硬件检测平台和上位机处理平台两个部分。硬件检测平台主要包括采集电路、主控电路和电源管理电路，将采集到的原始表面肌电信号打包处理，通过串口传送至上位机处理平台，可以对数据进行保存和分析处理，实现对肌肉疲劳三种状态的分类。




图 3.1 系统的总体框架

3.2 硬件检测平台设计

3.2.1 采集电路

表面肌电信号容易受到外界环境和其他生理信号的影响，因此硬件检测平台前端采集电路极为重要。本系统中肌电传感器选择了 MyoWare 肌电传感器作为表面肌电的前端采集传感器，MyoWare 肌电传感器集成了模拟前端，可以进行初步的放大和滤波。MyoWare 肌电传感器通过记录肌肉收缩时的电活动，对采集到的肌电原始信号进行放大处理，得到易于分析的信号数值。采集电路框图如图 3.2 所示。肌电传感器共有三个氯化银电极卡扣，该材料可以减小线性漂移，去除极化现象，其中两个采用差分采集的电极和一个用于滤除运动干扰的参考电极。两个差分电极固定在电路板上，另一端贴上一次性肌电贴，贴于测试肌群凸起肌肉处；参考电极一般贴在肌肉边缘处，如手肘处。




图 3.2 采集电路框图

放大电路选择 AD8648 芯片作为运算放大器，AD8648 是四路、轨对轨的单电源放大器，具有低失调电压，宽信号带宽、低输入电压、低电流噪声和单位增益稳定等特点。还具有低功耗关断功能，它的些特性使其适用于多种电路。AD8648 带宽为 24MHz，失调电压最大为 2.5mV，短路输出电流为 120mA。放大电路如图 3.3 所示。




图 3.3 放大电路

3.2.2 主控电路

主控 CPU 选自 STM32F4 系列的微处理器，型号是 STM32F405RGT6，具有高达 1MB 的 Flash 存储器，并具有加密功能，以及 16 个通用的 DMA 控制流。所选芯片拥有高性价比、低功耗和低电压的特点，同时还保持了高集成和易于开发的优点。它是基于 ARM Cortex-M4 内核的微处理器，闪存执行命令性能可达到 225MIPS。此外，还具有丰富的外设接口，提供了完整的 DSP 指令集合。主控模块主要完成对系统中各个模块的控制，以及与上位机的数据传输，电路原理图如图 3.4 所示。

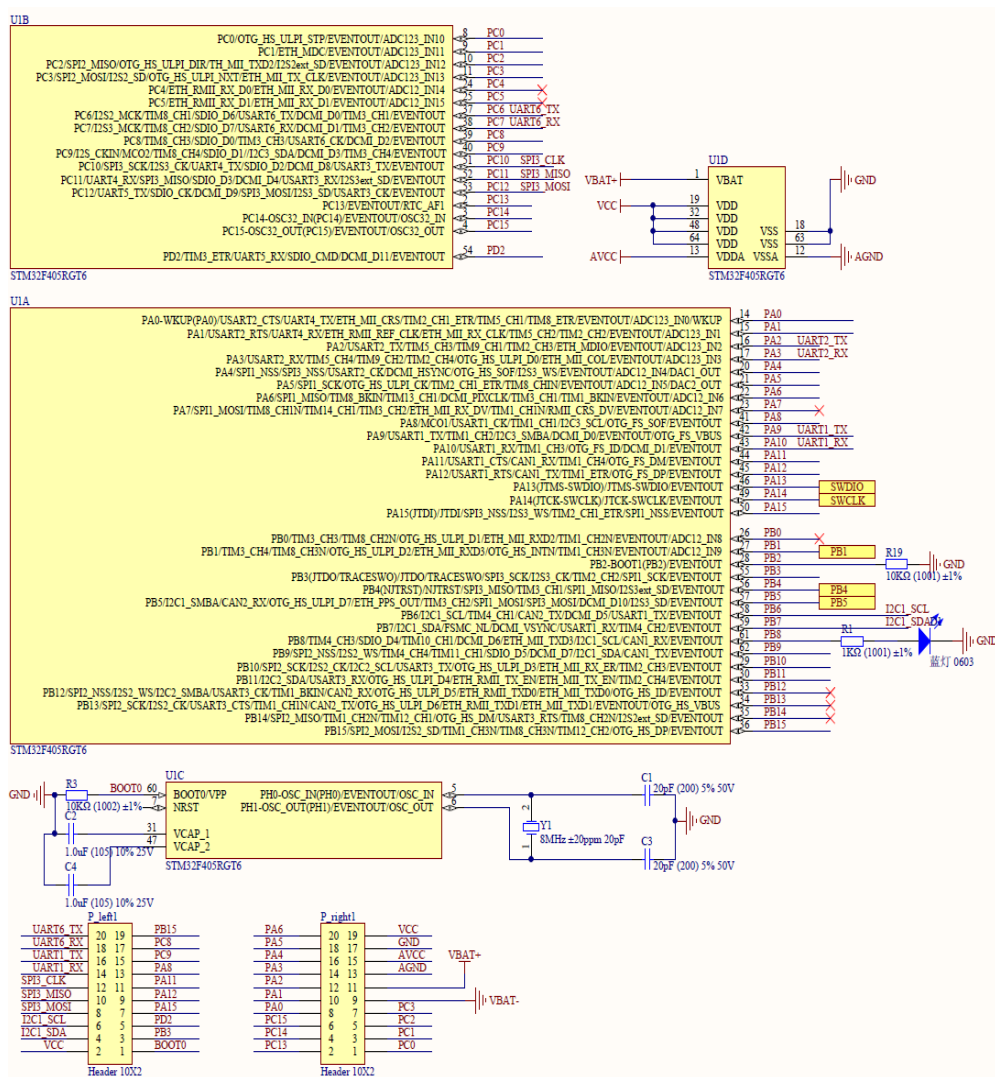


图 3.4 STM32F405RGT6 电路图

通过主控芯片 STM32F405RGT6 自带的 A/D 转换器中的 3 个通道采集右手臂三块肌肉的表面肌电传感器输出的模拟信号，在下位机中将表面肌电信号打包

成数据包，通过串口，发送到上位机检测平台。A/D 转换电路采集和多路复用器的驱动由定时器控制。此外，A/D 转换后的表面肌电信号数据，可以采用 DMA 传输，不经过下位机 CPU，直接通过串口将打包的数据传送给上位机，此设计能够显著提升下位机的运行效率。下位机主控电路程序框图如图 3.5 所示。另外上位机设定了对下位机的控制指令字节，通过 USART 串口，控制下位机的开始采集与结束采集。上位机通过时钟计时，当到达指定时间时，向下位机发送暂停采集命令并将控制系统采集的数据保存至上位机指定位置处。




图 3.5 下位机主控电路程序框图

3.2.3 电源管理电路

可以通过两种方法对电路板进行供电，一种是通过 Micro USB，Micro USB 是 USB 2.0 标准的一个便携版本，同时提供数据传输和充电，具有高达 10000 次的插拔寿命和强度，比标准的 Mini USB 和标准的 USB 连接器更小，应用更为广泛；另一种是通过聚合物锂电池，聚合物锂电池是锂电池的一种，标准电压为 3.7V，充满电是 4.2V，最大允许电流 2A，能够提供稳定的电压，有效防止不稳定电流

对电路板的伤害。聚合物锂电池如图 3.6 所示。



图 3.6 聚合物锂电池

选择 TP4057 芯片对电路板进行电源管理，TP4057 是一款单节锂离子电池充电器，采用恒定电流/恒定电压线性控制，由于内部采用了 PMOSFET 架构，加上放倒充电电路，不需要外部隔离二极管。充满电压固定于 4.2V，当达到 4.2V 后，充电电流降至设定值的十分之一，TP4057 将自动终止充电。最大充电电流为 600mA，预充电电压为 $4.2V \pm 1\%$ ，封装形式为 SOT23-6L。电源管理电路如图 3.7 所示




图 3.7 电源管理电路

为了节省 IO 资源，减小电路板的体积，用最少的 IO 口扫最多的键，设计了多功能按键电路，即通过一个按键控制多个电路功能。主要设置了以下几种功能，包括短按开机，长按关机，开机状态下的短按检测和长按检测。多功能按键电路如图 3.8 所示。




图 3.8 多功能按键电路

稳压芯片选择 XC6206 系列，型号是 XC6206P332PR，它是一款高精度，低功耗，三引脚的 LDO 高电压调整芯片，采用 CMOS 工艺和激光微调技术。XC6206P332PR 芯片内部包括一个电流限制电路，一个驱动三极管，一个高精度参考电压源和一个误差校正电路。芯片的输出电压为 1.2V 至 5V，最大输出电流为 500mA。通过 XC6206P332PR 芯片设计了两路电源电路，为各个芯片供电以及提供稳定的 3.3V 电压。稳压电路图如图 3.9 所示。




图 3.9 稳压电路图

当前表面肌电采集设备一般采用数据线 USB 把 sEMG 传输到上位机，需要靠近 PC 端，存在一定的局限性。本文在 USB 的基础上，添加了 TF 卡存储，便于运动员的使用。使用金士顿 8G TF 卡存储表面肌电信号，它是一种极小的快闪存储器卡，插入 SD 卡槽中使用。其电路原理图如图 3.10 所示。




图 3.10 TF 卡存储电路图

3.3 上位机处理平台设计

上位机处理平台是表面肌电信号采集系统的重要组成部分，主要功能包括：实现对硬件检测平台的控制，接收并处理 sEMG 数据，显示 sEMG 的数据变化，提取五类特征参数，特征降维以及建立疲劳分类模型等。上位机处理平台的总体设计框图如图 3.11 所示，主要模块包括数据传输模块、数据处理模块、疲劳分析模块和显示界面模块。本文采用 Visual Studio 2019 与 Matlab 2015b 两个软件来设计上位机处理平台。Visual Studio 2019，它是跨语言软件平台，可以使用多种语言开发，本文使用 C#编程语言，可以设计出比较友好的界面。




图 3.11 上位机处理平台的总体设计

数据传输模块部分是利用串口的方式与硬件检测平台连接，首先配置端口，

检查端口是否成功配对；然后接收并解析下位机通过串口发送的表面肌电信号的数据包。数据处理模块主要包括对表面肌电信号的噪声处理以及数据标签化。表面肌电信号容易受到其他生物电信号、硬件设备的固有噪声等干扰，因此需要对采集到的表面肌电信号进行噪声处理。同时需要对表面肌电信号进行标签化处理，为后续的疲劳分析准备。疲劳分析模块可以分为特征提取、特征降维和建立疲劳分类模型等。

上位机波形显示界面如图 3.12 所示，可以实时显示表面肌电信号，也可以导入离线文件。在波形显示界面添加了开始和停止按钮，用来控制对表面肌电信号的采集，便于对后续的断点分析。当每接收到一个数据包时，进入一次回调函数，在回调函数中对数据进行存储。同时添加了打开文件按钮，可以对离线信号进行分析。然后将采集到的 sEMG 信号保存为.csv 格式，通过 Matlab 进行特征提取，特征分析以及后续的分类。




图 3.12 上位机显示界面

3.4 本章小结

本章基于表面肌电信号的特点，设计了一种可以实时显示的 3 通道表面肌电信号采集系统，包括硬件检测平台和上位机检测平台的设计。其中硬件检测平台主要包括采集电路，主控电路和电源管理电路；上位机处理平台包括对数据传输、数据处理、疲劳分析和波形显示等功能。

第4章 特征降维与分类模型的分析方法

在第二章提出了表面肌电信号的六种时域特征参数均方根值、积分肌电值、平均绝对值、过零率、方差和幅值立方均值，三种频域特征参数平均功率频率、谱矩和中位频率，两种时频域特征参数瞬时平均频率和瞬时中值频率，一种非线性特征参数近似熵和一种参数模型特征4阶自回归模型，以及第三章介绍的3通道表面肌电采集系统，3通道共可以采集48维特征参数。高维数据会加大后续的模型训练时间，同时特征之间也存在冗余性，影响分类识别的准确率。因此在在对疲劳模型训练之前，需要对表面肌电的特征进行特征降维。

4.1 特征降维

本文基于3通道sEMG信号，共可提取48维特征参数。高维数据包含大量的冗余特征，这些冗余特征会对后续的分类产生影响以及增加运算的复杂度，而且高维数据会引起“过拟合”、“维数灾难”等问题，降低分类器的性能^[59]。提取有效的特征参数是疲劳分类的关键，因此需要对特征集进行降维，提高分类模型识别率。特征降维主要分为特征选择和特征提取，图4.1整体算法流程图。




图 4.1 整体算法流程图

4.1.1 特征选择

特征选择是按照某种评价准则，从特征集中选用一些最有效的特征，从而降低特征维度的过程^[60]。Dash^[61]等给出了特征选择的框架，如下图 4.1 所示。




图 4.2 特征选择的框架

互信息（MI）度量是特征选择重要的度量方法之一，不用预先考虑样本的分布情况，而且可以处理线性或者非线性的随机变量。MI 值越大，可以说明两个变量之间的相关程度越大，反之则越小。

MI 的计算公式如下所示：

$$I(U;V) = \sum_{u \in U} \sum_{v \in V} p(u,v) \log \frac{p(u,v)}{p(u)p(v)} \dots\dots\dots (4.1)$$

式中 $p(u,v)$ 是 U 和 V 的联合概率分布函数， $p(u)$ 和 $p(v)$ 分别是 U 和 V 的边缘概率分布函数。

4.1.2 特征提取

特征提取是通过线性或非线性转换将原始数据特征映射到低维子空间，在不丢失原始数据信息的情况下减小特征数量^[62]。本研究采用主成分分析（Principal Component Analysis, PCA）以及核主成分分析（Kernel Principal Component Analysis, KPCA）两种特征提取方法。

（1）主成分分析方法

主成分分析是一种常用的线性特征提取方法，即对于一组可能不存在线性关系的数据，主成分分析将数据通过正交变换，映射到线性无关的低维子空间中，其算法基本原理是：计算原始各维数据的协方差矩阵以及特征值、特征向量，将特征值按照从大到小排列，保留数据的高贡献率的成分，忽略数据的低贡献率的成分，从而实现特征降维^[63]。

设 N 维随机向量 $x_i, i=1,2,\dots,M$ ，其中 M 为样本总数， N 为数据的维数。则

样本可以构成 $M \times N$ 的矩阵，即 $X = \begin{pmatrix} x_{11} & \dots & x_{1N} \\ \vdots & \ddots & \vdots \\ x_{M1} & \dots & x_{MN} \end{pmatrix}$ 。

按列求矩阵 $X_{M \times N}$ 每一列的均值，计算每一列减去该列的均值，公式如下所

示，用每一列的数减去相应列均值，得到新的矩阵 $B = \begin{pmatrix} \overline{x_{11}} & \dots & \overline{x_{1N}} \\ \vdots & \ddots & \vdots \\ \overline{x_{M1}} & \dots & \overline{x_{MN}} \end{pmatrix}$

$$\overline{x} = x_i - \frac{1}{M} \sum_{i=1}^M x_i \dots\dots\dots (4.2)$$

然后根据式(4.2)求得其转置矩阵 B^T ，计算特征协方差矩阵 C ，公式如下

$$C = B^T \times B \dots\dots\dots (4.3)$$

接着计算协方差矩阵 C 的特征值 λ_i 与特征向量 β_i ，将特征值 λ_i 按照从大到小的顺序排列，按照贡献率选取适当的前 k 个出成分，重新构成新的数据。前 k 个特征向量构成的矩阵如式 (4.4) 所示

$$W = (\beta_1, \beta_2, \dots, \beta_k) \dots\dots\dots (4.4)$$

计算降维至 k 维的重构数据 $P = W \times X$ 。

(2) 核主成分分析方法

部分疲劳特征值与疲劳之间可能表现为非线性关系，因此，我们需要一种新的方法来解决此问题。核主成分分析是主成分分析的改进算法，是一种非线性特征提取方法，解决主成分分析所无法实现的问题，与主成分分析相比大大减小了计算量，且提供了更优的识别性能。其基本原理如下：首先经过非线性映射，将数据转换到一个高维非线性空间中，然后使用线性 PCA 再映射到另一个低维空间。

对于 n 个输入样本的数据 $x_k (k=1,2,\dots,n), x \in R^N$ ，引入非线性映射函数 Φ ，将数据 x_k 转变为 $\Phi(x_k)$ ，则在新的特征空间中，协方差矩阵 C 为

$$C = \frac{1}{n} \sum_{i=1}^n \Phi(x_j) \Phi^T(x_j), j=1,2,\dots,n \dots\dots\dots (4.5)$$

利用迭代法求解特征值 $\lambda(\lambda > 0)$ 与特征向量 $V(V \neq 0)$

$$\lambda V = CV \dots\dots\dots (4.6)$$

而 V 可由 $\Phi(x_k)$ 线性表示

$$V = \sum_{j=1}^n \alpha_j \Phi(x_j), j = 1, 2, \dots, n \dots\dots\dots (4.7)$$

式中 α_j 为方程系数，式 (4.6) 左乘 $\Phi(x_k)$ 得

$$\lambda(\Phi(x_k) \cdot V) = \Phi(x_k) \cdot CV, k = 1, 2, \dots, n \dots\dots\dots (4.8)$$

定义一个 $n \times n$ 的矩阵 K

$$K_{ij} = \Phi(x_i) \Phi(x_j), i, j = 1, 2, \dots, n \dots\dots\dots (4.9)$$

求解核矩阵 K 的非零特征值 λ 与特征向量 α

$$n\lambda\alpha = K\alpha \dots\dots\dots (4.10)$$

中心化的特征向量为 V ，样本数据 $\Phi(x)$ 在 V 上映射为

$$h_i(x) = (V, \Phi(x)) = \sum_{i=1}^n \alpha_i \Phi(x_i) \dots\dots\dots (4.11)$$

$h_i(x)$ 为 $\Phi(x)$ 的第 k 个非线性主成分向量。

4.2 肌肉疲劳分类器选择

疲劳分类是建立疲劳模型的最后一步，在对提取的表面肌电信号特征降维后，将其输入到分类器中进行训练。本文采用 Fisher 线性判别分析、K 近邻和支持向量机三种分类器对疲劳进行分类。

4.2.1 Fisher 线性判别分析

Fisher 线性判别分析 (Fisher Linear Discriminant Analysis, FLDA) 在二十世纪九十年代引入模式识别领域，是模式识别中的经典算法。线性判别分析是监督学习一种，需要提前对数据贴上分类标签，其基本思想是将高维数据投影到最佳辨别低维矢量空间中，在新的子空间中，使同类样本之间的间距达到最大，不

同类别之间的样本间距达到最小，即同类样本的尽可能的聚集，不同类别的样本尽可能的分散^[64]。Fisher 线性判别分析原理示意图如图 4.3 所示。




图 4.3 Fisher 线性判别分析原理示意图

给定样本集 $(x_i, y_i), i = 1, 2, \dots, n, x \in R^N, y \in \{-1, 1\}$ ，第 y 类样本的均值和方差可以表示为：

$$\begin{aligned}\mu_y &= \frac{1}{N_y} \sum_{x_i \in y} x_i \\ s_y^2 &= \sum_{x_i \in y} (x_i - \mu_y)^2 \dots\dots\dots (4.12)\end{aligned}$$

式中 N_y 表示第 y 类样本点的数目，将 (x_i, y_i) 映射到方向向量 γ 上，则第 i 个样本点在其上的投影为：

$$z_i = \gamma^T x_i \dots\dots\dots (4.13)$$

则第 y 类样本映射到方向向量 γ 上的均值和方差可以表示为：

$$\begin{aligned}v_y &= \gamma^T \mu_y \\ \sigma_y^2 &= \sum_{z_i \in y} (z_i - v_y)^2 \dots\dots\dots (4.14)\end{aligned}$$

当同类样本间距与不同类样本间距的比值最大时，可求得最佳方向向量 γ ，则要求：

$$\arg \max J(\gamma) = \frac{v_{-1} - v_1}{\sigma_{-1}^2 - \sigma_1^2} \dots\dots\dots (4.15)$$

将式(4.14)中的均值与方差带入式(4.15)可得:

$$\frac{\gamma^T(\mu_{-1}-\mu_1)(\mu_{-1}-\mu_1)^T\gamma}{\sum_{x_i \in y_{-1}} \gamma^T(x_i-\mu_{-1})(x_i-\mu_{-1})^T\gamma + \sum_{x_i \in y_1} \gamma^T(x_i-\mu_1)(x_i-\mu_1)^T\gamma} \dots\dots\dots (4.16)$$

式中 $(\mu_{-1}-\mu_1)(\mu_{-1}-\mu_1)^T$ 称为类间散度矩阵, 可用 s_a 表示。 $(x_i-\mu_{-1})(x_i-\mu_{-1})^T$ 与 $(x_i-\mu_1)(x_i-\mu_1)^T$ 称为协方差矩阵, 用 s_ω 表示两者之和, 即类内散度矩阵。式(4.16)化简后为:

$$\arg \max J(\gamma) = \frac{\gamma^T s_a \gamma}{\gamma^T s_\omega \gamma} \dots\dots\dots (4.17)$$

式中 s_a 与 s_ω 称为广义瑞利商, 令 $\gamma^T s_\omega \gamma = 1$, 采用 Lagrange 乘子法计算矩阵 $s_a^{-1}s_\omega$ 的最大特征值 λ 与对应特征向量 β , β 也就是方向向量 γ 的最佳取值。

4.2.2 K 近邻

K 近邻(K-Nearest Neighbor, KNN), 于 20 世纪六十年代由 Cover 等人提出, 是一种典型的监督学习算法。K 近邻算法的核心思想是: 计算待分类测试集样本与训练集样本之间的距离, 找出其中最近的 K 个训练样本点, 将待分类测试集样本归为这 K 个训练集样本点中出现最多的所属类别中^[65]。K 近邻原理示意图如图 4.4 所示。




图 4.4 K 近邻原理示意图

K 近邻算法有三要素，包括 K 值的选择，距离度量以及决策规则。K 值过大会产生欠拟合，而过小有会产生过拟合，影响分类的识别率，一般采用交叉验证的方式来设置 K 值数；距离度量有多重方法，常见的有欧氏距离、曼哈顿距离等，本文采用欧氏距离；对于决策规则，在模式识别中，一般采用“多数表决策法”。

设样本集为 $(x_i, y_i), i=1, 2, \dots, n, (x_i, y_i \in Z)$ ，欧式距离的计算公式为：

$$d(x_i, y_i) = \sqrt{\sum_{i=1}^n (x_i, y_i)^2} \dots\dots\dots (4.18)$$

计算样本集中样本点的距离，并根据距离大小进行降序排列；选择当前所需分类样本点最近的 K 个点，采用“多数表决策法”，选择出现频率最高的样本点的类，作为测试样本点预测的类。

4.2.3 支持向量机

支持向量机（Support Vector Machine, SVM）是由 Vapnik 等首先提出的，是基于统计学理论的 VC 维理论和结构风险学最小理论基础的一种机器学习算法^[66]。核心策略是寻找一个最优的超平面，使支持向量到超平面的距离最大，即最大化类与类之间的间隔，能够应用于高维度特征和非线性分界面等情况，是一种典型的二分类模型。SVM 算法出现后，因其分类性能的优势被广泛研究，主要体现在系统结构简单，全局最优，推广能力强，学习和预测时间短^[67]。支持向量机原理示意图如图 4.4 所示。




图 4.5 支持向量机原理示意图

给定训练集样本 (x_i, y_i) , $x \in R^n$, $y \in (-1, 1)$, 设超平面 $\omega \cdot x + b = 0$ 。为了使训练集样本分类正确, 则要求:

$$y_i[(\omega \cdot x_i + b)] \geq 1, \quad i = 1, 2, \dots, n \quad (4.19)$$

由支持向量可以得到 $y_k[(\omega \cdot x_k + b)] = 1$, 计算得到分类间隔为 $2/\|\omega\|$, 可以转化为带有约束条件 (4.19) 的最小值问题

$$\min \Phi(\omega) = \frac{1}{2} \|\omega\|^2 = \frac{1}{2} (\omega \cdot \omega) \quad (4.20)$$

引入 Lagrange 函数 $L = (\omega, b, \alpha)$, 对 ω 和 b 求偏导后带入, 从而转化为对偶问题

$$\begin{aligned} \max \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i \cdot x_j \\ \text{s.t.} \quad & \sum_{j=1}^m \alpha_j y_j = 0 \\ & \alpha_i \geq 0, i = 1, 2, \dots, m \end{aligned} \quad (4.21)$$

经计算得到最优权值向量 ω^* 和最优偏置 b^* , 从而得到最优超平面 $(\omega^* \cdot x) + b = 0$, 继而得到最优分类函数为:

$$\text{sgn}\left\{\left(\sum_{i=1}^m \alpha_i^* y_i (x_i \cdot x_j)\right) + b^*\right\} \quad (4.22)$$

4.3 本章小结

本章主要介绍了疲劳分类过程中最重要的两个环节, 特征降维和分类器的选择。由于采集的表面肌电信号的特征集维度较高, 需要对特征集进行降维处理, 减小特征的冗余度, 提高模型的识别率。分别介绍了特征选择中互信息度量方法与特征提取中主成分分析和核主成分分析两种方法。最后介绍了 Fisher 线性判别分析、K 近邻和支持向量机三种分类器的算法原理以及各自的优点。

第5章 疲劳分类实验与结果分析

当人体进行持续性的对抗力时,会产生肌肉疲劳,肌肉疲劳会使人感到酸痛无力,严重时会导致肌肉损伤,影响人的正常生活。尤其是在体育训练中,运动员为获得优异的成绩,需要进行大量的训练,但是大量的训练造成肌肉疲劳,当肌肉疲劳到达一定程度是会产生肌肉损伤。为了在体育训练中,使运动员进行合理有效的训练,需要对于动员进行疲劳判断。对于疲劳的划分,一般将肌肉划分为轻松态,疲劳过渡态和疲劳态三种状态。选择不同表面肌电信号特征以及不同的分类器,都会影响最终的疲劳分类结果。本章首先设计疲劳诱发实验,提取sEMG的特征参数,然后分析随着疲劳程度的加深,特征参数的变化规律。最后将降维后的新的特征集带入不同分类器中训练,通过比较九种疲劳分类模型对肌肉状态的识别率,选择最优肌肉疲劳分类模型。

5.1 疲劳实验方案设计

5.1.1 实验对象及材料

实验对象为本实验室的12名研究生,其中6名男生,6名女生,均为右手使用者,无神经肌肉骨骼疾病。身体状况良好,年龄在23~29岁之间,实验前24小时未进行高强度的运动,无身心疲劳。每位实验对象在实验前都被告知实验流程,同时签订知情同意书。

选择受试者右手臂的主要发力肌肉群:肱二头肌、肱三头肌和肱桡肌为检测部位。不同性别、年龄、身高、体重的受试者,其肌电值的幅度存在一定的差异,可能会影响后续的分类结果。身体质量指数(BMI)是衡量人体胖瘦以及是否健康的一个标准,当分析受试者体重对于不同高度所带来的影响时,BMI是一个可靠地标准。性别、年龄、身高、体重以及身体质量指数(BMI)如下表5.1所示。

表 5.1 十二名实验对象的基本信息

实验对象	性别	年龄	身高/cm	体重/kg	BMI	分类
Subject 1	女	25	163	51	19.20	正常
Subject 2	男	26	171	68	23.26	正常
Subject 3	女	23	170	57	19.72	正常
Subject 4	女	23	158	48	19.23	正常
Subject 5	女	23	158	47	18.82	偏瘦
Subject 6	男	25	171	66	22.57	正常
Subject 7	男	25	180	65	20.06	正常
Subject 8	男	24	181	73	22.28	正常
Subject 9	女	28	172	59	19.94	正常
Subject 10	女	24	176	60	19.37	正常
Subject 11	男	26	176	80	25.83	偏重
Subject 12	男	29	168	65	23.03	正常

注：BMI 中国参考标准，正常范围 18.5~23.9，偏瘦 BMI≤18.4，偏重 24.0~26.9，肥胖≥27.0。

实验材料包括 75%酒精棉、磨砂膏，用于清洁手臂肱二头肌、肱三头肌、肱桡肌的皮肤表面，增加表面肌电信号的导电性；一次性肌电贴，肌内效贴布，5kg 哑铃；三通道 sEMG 采集系统，采集原始表面肌电信号。

5.1.2 实验过程

实验前给予受试者相应动作指导帮助其熟悉 Borg 主观疲劳等级量表，然后根据个人情况进行若干次预实验使受试者熟悉实验过程。以往研究，实验多采用由记录者每隔固定时间询问受试者状态，这样容易干扰受试者，给予受试者一定的心理压力，而且不同受试者达到疲劳程度的时间也不尽相同，容易错过相应的疲劳等级。所以本实验采用受试者根据自身主观疲劳感受主动报告主观疲劳等级量表 RPE 分数，主观疲劳等级量表 RPE 得分以及划分如表 5.2 所示，将 RPE 分数 6-11 划为轻松态，12 至 18 为疲劳过渡态，19 至 20 为疲劳态。

表 5.2 主观疲劳等级量表 RPE 得分以及状态划分

等级	自我感受	疲劳状态
6	休息	轻松态
7	极其轻松	
8	很轻松	
9		
10		
11	轻松	
12	有点吃力	
13		
14		
15	吃力	疲劳过渡态
16		
17		
18	很吃力	
19	极其吃力	疲劳态
20	筋疲力尽	

模式识别算法主要包括监督学习，半监督学习和无监督学习。监督学习亦称有教师学习，即利用已知的有标签样本（事先人为对数据进行标记），调整分类器参数，通过标签和数据对应的映射关系来建立模型。半监督学习利用两个样本集，其中一个样本集为有类别的标签数据，另一个为无类别的标签数据，建立合适的分类模型。无监督学习利用的数据集合，没有任何标签，需要机器对数据集进行建模，例如聚类。本文采用监督学习，需要对表面肌电数据进行标签化，生成轻松态，疲劳过渡态和疲劳态数据集。其中将轻松的标签设为-1，疲劳过渡态的标签设为 0，疲劳的标签设为 1。

受试者闭眼放松倚靠在凳子上休息 2~3 分钟，达到最佳身心放松状态。用磨砂膏，酒精棉清洁皮肤表面，减少皮肤阻抗的干扰。根据解剖学原理，将表面肌电传感器的两个差分电极按照中心间隔 2cm 的距离贴合在目标肌肉凸起最高位置，参考电极尽量远离测试肌肉，一般贴合在肘部的骨头处。一次性表面肌电贴

在贴合时，为了使它与肌肉粘附更加紧密，获得更加准确的表面肌电信号，可以使电凝胶的表面沾少量的水。用肌内效贴布将传感器缠绕在右手肱二头肌、肱三头肌、肱桡肌的测试部位，防止实验时电极贴的脱落。

受试者正坐于椅子上，颈部、背部挺直，躯干与大腿，大腿与小腿分别保持 90° ，左手平放在左腿上，右前臂与右上臂保持 90° ，略微靠近躯干。实验开始后，首先采集三秒无负重状态下数据；随后将哑铃放于受试者手中，继续保持无负重状态下的姿势，然后开始采集负重状态下肌电数据，数据采集如图 5.1 所示。采集过程中，受试者保持恒力托举哑铃，操作员记录受试者的主观疲劳等级量表 RPE 值与相应的时间，并观察受试者的右臂关节角度，抖动状况，随时了解受试者的主观感受。当受试者的右前臂与右上臂无法保持 90° 或者右臂剧烈颤抖时结束数据采集。重复以上操作，直至 12 名受试者数据全部采集完成，因人差异，可能采集时间与疲劳时间会略有差异，需要操作员在一旁给予适当的语言鼓励，使受试者尽可能保持 50s 以上的负重状态数据采集。



图 5.1 表面肌电信号的采集

5.2 实验结果分析

5.2.1 特征分析

因实验开始和结束阶段采集的不稳定，所以截取实验开始 5s 后和停止前 5s 的信号作为原始表面肌电信号，其中一名典型受试者（subject 1）疲劳进程中的

肱二头肌、肱三头肌、肱桡肌的表面肌电信号如图 5.2 所示。




图 5.2 受试者右手臂 3 块肌肉表面肌电信号

图 5.2 分别为肱二头肌，肱三头肌，肱桡肌表面肌电信号，横坐标为采样点数，纵坐标为肌电信号幅值。可以看出负重状态下，随着时间的持续，3 块肌肉表面肌电信号的幅值都有增大的趋势。但是，不同部位的幅值增大的趋势不相同，其中肱二头肌幅值增大较为明显。

对采集到的 sEMG 信号进行预处理后，设时间窗为 1000 个点，每次窗移动的距离为 200 个点，分别计算受试者的各个特征值。选择受试者 (subject1) 的肱二头肌定量分析，提取表面肌电信号的时域特征 (RMS、iEMG、ARV、MCV、ZC、VAR)，频域特征 (MPF、SM₂、MF)，时频域特征 (IMPF 和 IMF)，非线性特征 (ApEn) 和参数模型 (AR4)。如图 5.3~5.6 分别为受试者肱二头肌随着负重的持续各特征变换曲线图。




图 5.3 受试者肱二头肌时域特征值变化




图 5.4 受试者肱二头肌频域特征值变化




图 5.5 受试者肱二头肌频域特征值变化




图 5.6 受试者肱二头肌非线性和参数模型特征变化

如图 5.3~5.6 所示,随着疲劳程度的加深,sEMG 信号的时域、频域以及时频域特征、非线性特征和参数模型特征存在不同程度的变化。从图 5.3 可以看出,随着负重的持续,表面肌电信号的时域特征 RMS、iEMG、ARV、MCV,VAR 均呈现上升趋势,ZC 出现下降趋势,且对疲劳均有较高的敏感性,分析其原因,可能是在负重情况下,肌肉募集了更多肌纤维运动单元,从而产生了动作电位。图 5.4 为表面肌电信号的三个频域特征变化图,可以看出随着负重的持续,表面肌电信号的频域特征 MPF、MF 呈现下降趋势,分析其原因,可能是随着动作电位的增加,表面肌电信号的频谱左移,即向低频方向移动,而 SM_2 没有明显的变化趋势。图 5.5 为表面肌电信号的时频域特征图,随着负重的持续,IMPF 和 IMF 均有下降的趋势,表明其对疲劳也具有较好的敏感性。图 5.6 中的表面肌电信号的非线性特征,ApEn 也出现了明显的下降趋势,表明了其非线性的特点以及肌肉的运动神经单元在时间、空间以及数量上存在一定的差异,说明了随着疲劳程度的加深,表面肌电信号的时间序列的复杂程度减小,而表面肌电信号的参数模型特征 AR4 并没有明显的变化趋势。

本文提取三通道表面肌电信号,共 48 个特征参数,每个特征运算的时间存在差异。表 5.3 为右手臂肱二头肌 16 个特征参数算法运行的时间。

表 5.3 肱二头肌 16 个特征参数算法运行的时间

特征算法	运行时间/s
RMS	0.0181
iEMG	0.0068
ARV	0.0065
ZC	0.0264
VAR	0.0462
ACM	0.0069
MPF	0.1422
FM ₂	0.1526
MF	0.1035
IMPF	0.1325
IMF	0.1832
ApEn	3.8013
AR4	0.0316

不同受试者以及不同 sEMG 特征存在不同的量纲和量纲单位，这样会影响到对 sEMG 数据的分析，因此有必要对这些特征的数据集进行归一化处理，使各特征参数处于同一量纲。本实验采用的归一化的方法是最大—最小标准化，公式如下：

$$x' = \frac{x - \min A}{\max A - \min A} \dots\dots\dots (5.1)$$

最大—最小标准化是对 sEMG 数据进行线性变换，设 $\min A$ 和 $\max B$ 分别是特征 A 的最小值、最大值，将 A 的原始数据 x 映射到区间 $[0, 1]$ 。

对于受试者，将其原始数据时间分成 38 段，求其每段的特征参数的均值。然后，分别对时间段与 sEMG 时域、频域以及时频域、非线性特征上的各特征进行曲线拟合，其中时域、频域、时频域特征各选两个，以时间段为自变量，sEMG 的特征为因变量，分别进行幂函数和指数函数的曲线拟合。图 5.7~5.13 分别是 RMS、iEMG、MPF、MF、IMPF、IMF、ApEN 的幂函数、指数函数拟合。




图 5.7 RMS 的幂函数、指数函数拟合




图 5.8 iEMG 的幂函数、指数函数拟合




图 5.9 MPF 的幂函数、指数函数拟合




图 5.10 MF 的幂函数、指数函数拟合




图 5.11 IMPF 的幂函数、指数函数拟合




图 5.12 IMF 的幂函数、指数函数拟合




图 5.13 ApEn 的幂函数、指数函数拟合

不同拟合方式下的判定系数 R^2 如表 5.4 所示。从表 5.4 可以看出，各拟合曲线均具有统计学意义， $P < 0.01$ ，说明各特征与疲劳均具有不同程度的相关性。但是，从拟合优先度的判定系数 R^2 看对于 sEMG 的时域特征 RMS、iEMG，幂函数拟合优于指数函数拟合，而对于 sEMG 的频域特征 MPF、MF，时频域特征 IMPF、IMF 和非线性特征 ApEn，指数函数拟合优于幂函数。

表 5.4 部分特征不同拟合方式下的判定系数 R^2

	Power	Exponential
RMS	0.757 **	0.661 **
iEMG	0.744 **	0.652 **
MPF	0.423 **	0.525 **
MF	0.423 **	0.525 **
IMPF	0.133 **	0.204 **
IMF	0.208 **	0.358 **
ApEn	0.494 **	0.710 **

** $P < 0.01$

5.2.2 特征降维分析

表 5.5 统计了表面肌电信号的时域、频域、时频域、非线性和参数模型特征维数。从表 5.5 可以看出，十六种特征提取方法，共可提取 48 维特征，维数的增加虽然在一定程度上会提升疲劳模型的识别率，但是同时也会增加模型的训练时间，因为特征之间存在大量的冗余信息。

表 5.5 表面肌电特征维数

特征类别	特征名称	维数
时域特征	RMS	18
	iEMG	
	ARV	
	ZC	
	VAR	
	ACM	
频域特征	MPF	9
	SM ₂	
	MF	
时频域特征	IMPF	6
	IMF	
非线性特征	ApEn	3
参数模型特征	AR4	12
总维数		48

选择部分特征，计算特征之间皮尔逊相关系数，如表 5.6 所示，可以发现时域内的两个特征参数 RMS 和 iEMG，频域内的两个特征参数 MPF 和 MF，时频域内的两个特征参数 IMPF 和 IMF 有很大的相关性。说明各特征之间存在不同程度的相关性，既存在有用信息，也存在冗余信息，因此将特征参数带入分类器之前需要对特征参数进行降维，选择合适的特征集合，减少模型的特征输入，来提高分类器的性能和减小模型训练时间。

表 5.6 部分特征之间的相关性

	RMS	iEMG	MPF	MF	IMPF	IMF
RMS	1.000**	0.906**	-0.871**	-0.862**	-0.764**	-0.758**
IEMG	0.906**	1.000**	-0.749**	-0.723**	-0.668**	-0.632**
MPF	-0.871**	-0.749**	1.000**	0.979**	-0.848**	0.847**
MF	-0.862**	-0.723**	0.979**	1.000**	0.766**	0.780**
IMPF	-0.764**	-0.668**	0.848**	0.766**	1.000**	0.865**
IMF	-0.758**	-0.632**	0.847**	0.780**	0.865**	1.000**

** $P < 0.01$

实验中，将采集到的 sEMG 的数据分为轻松态，疲劳过渡态，疲劳态三个状态，标签分别为-1，0，1。KPCA 处理得到的主成分的特征值与累计贡献率如图 5.14 和 5.15 所示。




图 5.14 KPCA 特征值变化图




图 5.15 KPCA 处理得到的主成分累计贡献率

从图 5.14 和 5.15 可以看出第一主成分所占比例远大于其他主成分,为 43.6%,且在第 8 至 11 主成分附近趋于稳定。按照贡献率大于 85%为阈值,选取前 8 个主成分来代替原始变量。原始样本降维后的三维分布如图 5.16 所示。




图 5.16 KPCA 降维三维分布图

从图 5.16 可以看出,经 KPCA 降维后的 3 种状态的样本被明显的区分开,从而说明名此方法的可行性。

5.2.3 分类结果分析

本文采用十折交叉验证方法，其原理是将数据集分成 10 分，每次抽取 1 分作为测试集，其余 9 分作为训练集，每次训练都会得到对应的正确识别率，最后求 10 次均值，为模型的正确识别率，如图 5.17 所示。



图 5.17 十折交叉验证示意图

将降维后新的特征集带入 Fisher 线性判别分析、K 近邻、支持向量机三种分类器进行训练，计算出轻松态、疲劳过渡态和疲劳态三种不同状态的识别率，对比结果如图 5.18 所示。




图 5.18 三种状态的识别结果

从图 5.18 可以看出,九种不同组合的疲劳分类模型对于轻松态、疲劳过渡态和疲劳态存在不同程度的识别率。相同分类器下,与 MI、PCA 相比,KPCA 结合三种分类器构成的疲劳分类模型的性能均有一定的提升。

而对于轻松态、疲劳过渡态和疲劳态,三种分类器识别的正确率都大于 60%。同一种降维方法下,其中 Fisher 线性判别分析分类器对于三种状态的识别率最低,而支持向量机对于三种状态的识别率则最高,准确率均在 85%以上。相比于 Fisher 线性判别分析和 K 近邻的分类效果,支持向量机有了较大的提升。

表 5.7 为 MI、PCA、KPCA 三种降维算法与 FLDA、KNN、SVM 三种分类器组合对疲劳状态的平均识别率和平均运行时间。

表 5.7 不同组合的实验结果

方法	平均识别率(%)	平均运行时间 (s)
MI+FLDA	69.3	4.08
PCA+ FLDA	61.9	3.15
KPCA+FLDA	68.4	2.68
MI+KNN	77.1	4.35
PCA+KNN	80.8	3.77
KPCA+KNN	83.1	3.19
MI+SVM	83.6	4.15
PCA+SVM	86.9	3.73
KPCA+SVM	91.5	2.75

从表 5.7 可以看出,采用不同降维方法,Fisher 分类器的运行时间最短,但是其平均识别率较低;SVM 分类器的平均识别率最高,运算时间也较短,其中 KPCA 与 SVM 的组合具有最高的平均识别率,平均识别率达到 91.5%。

5.3 本章小结

本章介绍了疲劳诱发实验的设计,包括实验对象、实验材料和实验过程。提取了表面肌电信号特征,并分析了时域、频域、时频域、非线性以及参数模型特征变化规律。将互信息度量、主成分分析和核主成分分析三种降维方法得到的新的特征集分别与 Fisher 线性判别分析、K 近邻和支持向量机三种分类器组合,通

过对比九种疲劳分类模型的性能，结果发现 KPCA 与 SVM 的组合的疲劳分类模型平均识别率最高。

第6章 总结与展望

表面肌电信号是人体重要的一种生物电信号，是评估肌肉疲劳的重要指标。相比于主观测量法、生化测量法和生理测量法中的其他生理信号，表面肌电信号更加客观，无创采集同时蕴含着丰富的肌肉信息。随着计算机技术与传感器技术的发展，使用表面肌电判断肌肉疲劳逐渐成为当下关注的热点。因此本文提出了 sEMG 的特征分析与肌肉疲劳分类研究，设计了一套 sEMG 采集系统，提取表面肌电信号的五类特征参数，并设计了疲劳诱发实验。通过不同的降维算法，得到新的特征集合，最后分别与 Fisher 线性判别分析，K 近邻、支持向量机分类器组合建立九种疲劳分类模型。

本文的主要研究工作如下：

(1) 从运动员训练与日常生活运动等角度出发介绍了肌肉疲劳的研究意义，分析并总结当下肌肉疲劳的研究状况，针对特征参数之间的相关性和冗余性，没有考虑分类器训练的运算复杂度，影响分类识别率的问题，提出了 sEMG 的特征分析与肌肉疲劳分类研究。

(2) 通过对表面肌电信号的产生机制、特点的研究，提取了表面肌电信号的时域、频域、时频域、非线性和参数模型特征五种特征参数。设计了硬件采集电路与上位机分析系统，实现了 3 通道表面肌电信号的采集以及数据处理、分析。

(3) 设计了疲劳诱发实验，提取了右手臂肱二头肌、肱桡肌和肱三头肌的表面肌电信号，采用小波阈值去噪的方法，去除皮脂，其他生物电信号和元器件固有噪声的干扰。随着疲劳程度的加深，发现肱二头肌、肱桡肌和肱三头肌的表面肌电信号的幅度有明显的增大趋势，同时 sEMG 的五类特征参数均有不同程度的下降或者上升的趋势。

(4) 为了提高分类模型的识别率，采用互信息度量、主成分分析和核主成分分析三种特征降维方法，降低特征之间的冗余度，减小特征集的维度。将降维后新的特征子集带入 Fisher 线性判别分析、K 近邻、支持向量机分类器进行训练，结果表明 KPCA 与 SVM 相结合的疲劳分类模型，对于肌肉疲劳的识别率最高，为 91.5%。

对本文的研究内容，虽然取得了一定的成果，但是仍存在一些需要进一步改进和完善的方面：

（1）增加表面肌电信号的采集通道，采集更多的肌肉群，从而获得更加详细的肌肉疲劳信息。表面肌电信号常伴随着外界信号和其他生理信号的干扰，需要进一步的探究降噪的算法，获得更加准确的信息。

（2）本文的疲劳分类只规定了 3 种状态，可以对此进行更加细致的分类。主观程度的判断也存在一定误差，需要受试者进行多次模拟实验，熟悉主观疲劳等级量表每个等级的划分。

（3）构建分类模型需要大量的样本进行模型训练，受实验条件的限制，本文所使用的样本集较少，应该在后续的研究上增加样本数量。目前本文只是采用了监督学习中的三种分类算法，未来可以向半监督和无监督学习两方面深入。

参考文献

- [1] 侯言旭, 姜礼杰, 胡保华, 等. 基于边际谱熵的肌肉疲劳实时评估方法研究[J]. 仪器仪表学报, 2017, 38(7): 1625-1633.
- [2] Boyas S, Guevel A. Neuromuscular fatigue in healthy muscle: underlying factors and adaptation mechanisms[J]. Annals of Physical and Rehabilitation Medicine. 2011, 54(2): 88-108.
- [3] 运动生理学编写组. 运动生理学[M]. 北京: 人民体育出版社, 2018.
- [4] 林楠. 一种手持式表面肌电监测仪: CN211155788U[P]. 2020-08-04.
- [5] 谭文波. 一种新型表面肌电信号采集仪: CN209629652U[P]. 2019-11-15.
- [6] 王耀弘, 王艺颖, 张雯, 等. 一种表面肌电仪校准装置的设计[J]. 电子制作, 2019, (1): 89-90.
- [7] 方泓煜. 表面肌电的采集系统及应用研究[D]. 电子科技大学, 2017.
- [8] Hughes E, Bell A. A wireless surface electromyography system[C]. Vcu Etd Archive, 2007.
- [9] 李青青, 吴宗耀. 股内侧肌疲劳时表面肌电信号特征研究[J]. 中国运动医学杂志, 2006, 25(5): 547-550.
- [10] 王笃明, 王健, 葛列众. 静态负荷诱发肌肉疲劳时表面肌电信号(sEMG)变化与主观疲劳感之间的关系[J]. 航天医学与医学工程, 2004, 17(3): 201-204.
- [11] 徐明伟, 金龙哲, 于露等. 长时间颈部前屈对颈部肌肉疲劳的影响[J]. 工程科学学报, 2019, 41(11): 1493-1500.
- [12] 王琳, 付荣荣, 张陈, 等. 基于生物力学分析 Q 值对颈肌疲劳的反映效果[J]. 仪器仪表学报, 2017, 38(4): 878-885.
- [13] 曹昂, 张坤嘉, 刘睿, 等. 基于表面肌电信号的肌肉疲劳状态分类系统[J]. 计算机应用, 2018, 38(6): 1801-1808.
- [14] 糜超, 陈阳, 邹凌. 基于表面肌电的肌肉疲劳检测系统研究[J]. 现代电子技术, 2018, 41(20): 78-82.
- [15] 张毅, 祝翔, 罗元. 一种克服 sEMG 人机交互中肌肉疲劳的 SVM 算法[J]. 控制工程, 2014, 21(4): 467-471.

- [16]付梦龙. 基于表面肌电信号的实时在线肌肉疲劳估计方法研究[D]. 中国科学院大学, 2020.
- [17]Jero S E, Ramakrishnan S. Order Frequency Spectral Correlation Based Cyclo-nonstationary Analysis of Surface EMG Signals in Biceps Brachii Muscles[J]. Annu Int Conf IEEE Eng Med Biol Soc, 2019, 2019: 7165-7168
- [18]Moniri A, Terracina D, Rodriguez-Manzano J, et al. Real-Time Forecasting of sEMG Features for Trunk Muscle Fatigue using Machine Learning[J]. IEEE Trans Biomed Eng, 2021, 68(2): 718-727.
- [19]Bueno DR, Lizano JM, Montano L. Muscular fatigue detection using sEMG in dynamic contractions[J]. Annu Int Conf IEEE Eng Med Biol Soc, 2015, 2015: 494-497.
- [20]Xu B, Wu Q, Xi C, et al. Recognition of the Fatigue Status of Pilots Using BF-PSO Optimized Multi-class GP Classification with sEMG signals[J]. Reliability Engineering & System Safety, 2020, 199(2).
- [21]Rampichini, Susanna, et al. Complexity Analysis of Surface Electromyography for Assessing the Myoelectric Manifestation of Muscle Fatigue: A Review[J]. Entropy, 2020, 22(5): 529.
- [22]卫哲, 董哲, 尚颖, 等.浅谈表面肌电图和针式肌电图在临床中的应用[J]. 求医问药,2012, 10(2): 84-85.
- [23]Lan N. Analysis of an optimal control model of multi-joint arm movements[J]. Biol Cybern. 1997; 76(2): 107-117.
- [24]齐文靖. 基于相干分析的上肢肌电信号耦合方法[D]. 燕山大学, 2018.
- [25]彭威. 下肢 sEMG 的特征分析及步态识别算法的研究[D]. 电子科技大学, 2019.
- [26]李奂良. 基于表面肌电信号的手部动作识别与交互[D]. 河北大学, 2020.
- [27]张聪. 多通道表面肌电信号特征提取关键技术研究[D]. 中国科学院大学, 2020.
- [28]De Luca CJ. Physiology and mathematics of myoelectric signals[J]. IEEE Trans Biomed Eng, 1979; 26(6): 313-325.

- [29] Q Shao, TS Buchanan. Electromyography As a Tool To Estimate Muscle Forces[J]. Biomedical Engineering and Design Handbook, 2009, 1: 287-306.
- [30] 周明娟, 逯迈. 基于高阶滤波的肌电信号采集电路设计[J]. 传感技术学报, 2018, 31(1): 54-60.
- [31] 陆国冉. 基于 sEMG 的卒中上肢肌肉疲劳监测系统的设计[D]. 郑州大学, 2018.
- [32] 2021. 栾振. 基于 sEMG 的腿部疲劳状态智能识别系统的设计[D]. 南京邮电大学, 2019.
- [33] 李佳妮, 王云峰. 表面肌电信号的降噪处理[J]. 传感器与微系统, 2017, 36(7): 42-44.
- [34] Sun Z, Xi X, Yuan C, et al. Surface electromyography signal denoising via EEMD and improved wavelet thresholds[J]. Math Biosci Eng, 2020, 17(6): 6945-6962.
- [35] Zhang Y, Chen Y, Yu H, et al. Learning Effective Spatial-Temporal Features for sEMG Armband-Based Gesture Recognition[J]. IEEE Internet of Things Journal, 2020, 7(8): 6979-6992.
- [36] 王琳, 化成城, 姜鑫, 等. 基于颈腰部肌电及脑电信号的疲劳驾驶检测[J]. 东北大学学报, 2018, 39(1): 102-107.
- [37] Georgakis A, Stergioulas L, Giakas G. Fatigue analysis of the surface EMG signal in isometric constant force contractions using the averaged instantaneous frequency[J]. IEEE Transactions on Biomedical Engineering, 2003, 50(2): 262-265.
- [38] Kahl L, Hofmann UG. Comparison of algorithms to quantify muscle fatigue in upper limb muscles based on sEMG signals[J]. Med Eng Phys, 2016, 38(11): 1260-1269.
- [39] 于在洋, 张旭, 王东清, 等. 表面肌电信号复杂性与肌力关系研究[J]. 航天医学与医学工程, 2016, 29(2): 120-126.
- [40] 蔡立羽, 王志中, 张海虹. 表面肌电信号的复杂度特征研究[J]. 航天医学与医学工程, 2000, 13(2): 124-127.
- [41] 古华光, 任维, 刘钢, 等. 近似熵及其在心率变异分析中的应用[J]. 航天医学与医学工程, 2000, 13(6): 417-421.
- [42] 赵翠莲, 马双驰, 柳叶潇. 基于样本熵和个体化阈值的表面膈肌肌电信号起

- 点检测[J]. 生物医学工程学杂志, 2018, 35(6): 852-859.
- [43] Trybek P, Nowakowski M, Salowka J, et al. Sample Entropy of sEMG Signals at Different Stages of Rectal Cancer Treatment[J]. Entropy, 2018, 20(11): 863.
- [44] Mugnosso M, Zenzeri J, Hughes CML, et al. Coupling Robot-Aided Assessment and Surface Electromyography (sEMG) to Evaluate the Effect of Muscle Fatigue on Wrist Position Sense in the Flexion-Extension Plane[J]. Frontiers in Human Neuroscience, 2019, 13: 396.
- [45] 崔永霞, 孙科. 基于肌电均方根和包络线的不同蹲起动作的肌电特征研究[J]. 山东体育科技, 2016, 38(6): 58-60.
- [46] Toro SFD, Santos-Cuadros S, Olmeda E, et al. Is the Use of a Low-Cost sEMG Sensor Valid to Measure Muscle Fatigue[J]? Sensors, 2019, 19(14): 3204.
- [47] Skavhaug IM, Lyons KR, Nemchuk A, et al. Learning to modulate the partial powers of a single sEMG power spectrum through a novel human-computer interface[J]. Human Movement Science, 2016, 47: 60-69.
- [48] Liu Q, Liu Y, Zhang C, et al. sEMG-based dynamic muscle fatigue classification using svm with improved whale optimization algorithm[J]. IEEE Internet of Things Journal, 2021, 2: 1.
- [49] 徐冷风. 疲劳状态下肌力预测研究[D]. 中国科学技术大学, 2019.
- [50] Yun I, Jeung J, Song Y. Non-Invasive Quantitative Muscle Fatigue Estimation Based on Correlation Between sEMG Signal and Muscle Mass[J]. IEEE Access, 2020, 8: 51-57.
- [51] 李燕. UHF 频段射频识别系统读写器仿真与信号测量[D]. 湖南大学, 2009.
- [52] 王晓龙. 基于改进的 Wigner-Ville 时频分析的城轨列车车轮不圆检测方法研究[D]. 南京理工大学, 2017.
- [53] 郭书超. 非平稳信号 Choi-Williams 分布研究与应用[D]. 大连理工大学, 2012.
- [54] Karlsson S, Yu J, Akay M. Time-frequency analysis of myoelectric signals during dynamic contractions: a comparative study[J]. IEEE Trans Biomed Eng, 2000, 47(2): 228-38.

- [55]赵诗琪, 吴旭洲, 张旭, 等. 利用表面肌电进行手势自动识别[J]. 西安交通大学学报, 2020, 54(9): 149-156.
- [56]金成敏, 曲峰, 赵享楠, 等. 双任务下楼梯行走时对下肢肌肉活动表现及加速度近似熵指数的影响[J]. 天津体育学院学报, 2018, 33(4): 362-368.
- [57]杨铮, 王立玲, 马东. 基于自回归模型表面肌电信号检测肌肉疲劳研究[J]. 中国生物医学工程学报, 2018, 37(6): 673-679.
- [58]崔建国, 王旭, 李忠海, 等. 基于 AR 参数模型与聚类分析的肌电信号模式识别方法[J]. 计量学报, 2006, 3: 286-289.
- [59]黄铨. 特征降维技术的研究与进展[J]. 计算机科学, 2018, 45(1): 16-21.
- [60]姚旭, 王晓丹, 张玉玺等. 特征选择方法综述[J]. 控制与决策, 2012, 27(2): 161-166.
- [61]Dash M. Feature selection for classification[J]. Intelligent Data Analysis, 1997.
- [62]Khalid S, Khalil T, Nasreen S. A survey of feature selection and feature extraction techniques in machine learning[C]. 2014 Science and Information Conference, IEEE, 2014.
- [63]景甜甜, 洪洁. 基于 PCA 和 ELM 的表面肌电信号手腕动作识别研究[J]. 重庆理工大学学报, 2019, 33(12): 96-100.
- [64]AlOmari, F., Liu, G. Analysis of Extracted Forearm sEMG Signal Using LDA, QDA, K-NN Classification Algorithms[J]. Open Automation & Control Systems Journal, 2014, 6(1): 108-166.
- [65]Zhang S. Challenges in KNN Classification[J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 5: 1.
- [66]安悦瑄, 丁世飞, 胡继普. 孪生支持向量机综述[J]. 计算机科学, 2018, 45(11): 29-36.
- [67]郭明玮, 赵宇宙, 项俊平, 等. 基于支持向量机的目标检测算法综述[J]. 控制与决策, 2014, 29(2): 193-200.

作者简介及科研成果

作者简介：

董梦坤，男，汉族，1994 年 4 月出生于江苏徐州。2014 年 9 月至 2018 年 6 月，就读于长春理工大学光电信息学院，电子信息工程专业，获得学士学位。2018 年 9 月至今，就读于吉林大学仪器科学与电气工程学院，精密仪器及机械专业，攻读硕士学位。研究方向为：生物医学信号检测技术及仪器。

科研成果：

- [1] 刘光达, 董梦坤, 许蓝予等. 基于 KPCA-SVM 的表面肌电信号疲劳分类研究[J]. 电子测量与仪器学报. (中文核心,已录用)
- [2] 刘光达, 董梦坤, 许蓝予等. 手臂疲劳时表面肌电信号特征分析[J]. 科学技术与工程. (中文核心,已录用)
- [3] Jing Cai, Ge Zhou, Mengkun Dong, Xinlei Hu, Guangda Liu, Weiguang Ni. Real-Time Arrhythmia Classification Algorithm Using Time-Domain ECG Feature Based on FFNN and CNN[J]. Mathematical Problems in Engineering, 2021, 2021.
- [4] 刘光达, 周葛, 董梦坤, 胡新蕾, 蔡靖, 倪维广. 基于 FFNN 和 1D-CNN 的实时心律失常诊断系统[J]. 电子测量与仪器学报, 2021, 35(3):35-42.

攻读硕士学位期间参与的科研项目：

- (1) 国家重点研发计划项目“科学化训练基地关键技术的应用、检验、转化和示范”，项目编号：2018YFF0300806-1。
- (2) 吉林省科技发展计划项目“面向医院、社区和家庭的穿戴式全参数健康监护仪的研发与应用示范”，项目编号：20200404205YY。

致谢

素年锦时指尖落，蓦然回首繁花落。行文至此，落笔为终，三年研究生学业生涯即将结束，非常幸运能与美丽的吉大在青春年少的岁月有一场美丽的邂逅，在这三年的研究生学习和生活中，我收获的不仅仅是知识，更多的是伴随着我这一生美好的回忆。

桃李不言，下自成蹊。首先要感谢我的导师刘光达教授，从读研生活开始的那一刻，刘老师就时刻教导我们要专心学术，告诫我们看书要用心看用脑子思考，要散发思维，看到问题的本质。在繁重的教学和工作状况下，刘老师主动关心我的学习和科研，从论文的选题、撰写到最终的定稿，刘老师都给了我悉心的指导和帮助，使我的毕业论文能够顺利完成。刘老师对工作的认真、对学术的钻研和对生活的热情，都值得我终生学习。能师从刘老师，我为自己感到庆幸。在此向刘老师表示最诚挚的敬意和感谢。

感谢实验室的蔡靖老师，在生活和科研中对我的帮助。每当我遇到挫折和困难时，蔡老师总会在一旁给予我鼓励，耐心的为我答疑解惑，帮助我走出困境。

感谢我实验室的同学们，是你们陪伴我在研究生的道路上勇往直前，营造一个积极向上的科研环境，给实验室带来很多欢声笑语。

感谢我的师兄周葛，师姐孙佳琪，师妹许蓝予等，对我学业上帮助，他们学术上一丝不苟的态度，在生活和学习中不断的影响着我。感谢他们在实验过程中和论文的撰写中对我的帮助。祝愿他们在今后的工作和生活中一帆风顺。

感谢我的室友刘乃嘉、邱仕林和马斌元，和你们度过了很多快乐开心的日子。谢谢你们给我加油打气，这份友谊我会一直放在心里。

父字开头，母字结尾了，二十余年的求学之路，他们不求回报的付出是我前进路上最大的支持。他们给了我前行的勇气和动力，是我可以全身心的完成我的学业。祝愿我的父母身体健康，万事如意。

文有所长，而感谢之意无尽矣。一路走来，要感谢的人有很多。山高路远，我们更高处相见！